

Clasificación Binaria de Minería Ilegal (Garimpo) en la Amazonía mediante Transfer Learning con ResNet50 sobre Imágenes Satelitales

Jean Anthony Ajra Huacso
*Escuela Profesional de Ingeniería de
Sistemas*
Universidad Nacional de San Agustín
Arequipa, Perú
jajra@unsa.edu.pe

Paul Andree Cari Lipe
*Escuela Profesional de Ingeniería de
Sistemas*
Universidad Nacional de San Agustín
Arequipa, Perú
pcaril@unsa.edu.pe

Fernando Miguel Garambel Marín
*Escuela Profesional de Ingeniería de
Sistemas*
Universidad Nacional de San Agustín
Arequipa, Perú
fgarambel@unsa.edu.pe

Luis Guillermo Luque Condori
Escuela Profesional de Ingeniería de Sistemas
Universidad Nacional de San Agustín
Arequipa, Perú
lluquecon@unsa.edu.pe

Alexandra Raquel Quispe Arratea
Escuela Profesional de Ingeniería de Sistemas
Universidad Nacional de San Agustín
Arequipa, Perú
aquispearr@unsa.edu.pe

Abstract—El monitoreo de la minería ilegal en la cuenca amazónica representa un desafío crítico para la conservación ambiental, limitado por la inescalabilidad del patrullaje terrestre y la fatiga visual inherente a la vigilancia manual de imágenes satelitales a gran escala. Para superar estas restricciones logísticas, esta investigación evalúa un clasificador binario de Inteligencia Artificial (IA) basado en el método de Aprendizaje por Transferencia (Transfer Learning) mediante la arquitectura profunda ResNet50 preentrenada en ImageNet, orientada a identificar cicatrices de extracción aurífera en recortes multispectrales de 128 x 128 píxeles. El equipo desarrolla y valida el modelo sobre el conjunto de datos público Amazonia Garimpo Binario, el cual reúne 111,584 muestras satelitales equilibradas entre presencia (50.22%) y ausencia (49.78%) de minería aluvial. La topología residual de la red permite extraer características espectro-espaciales complejas mitigando la degradación del gradiente, mientras que la técnica de aumento de datos dinámico mediante rotaciones, transformaciones afines y cambios de escala previene el sobreajuste. Utilizando la entropía cruzada binaria como función de pérdida y la optimización Adam, el sistema alcanza en el conjunto de validación una exactitud global del 76.27%, un valor F1-Score macro del 76.19% y una sensibilidad del 77.85% para la detección de minería activa. Este nivel de recuperación supera en 35.85 puntos porcentuales las referencias previas de clasificación en minería artesanal, lo que respalda la viabilidad operativa de las Redes Neuronales Convolucionales (CNN) como herramientas confiables para sistemas gubernamentales de alerta temprana en territorios tropicales. — The monitoring of illegal mining in the Amazon basin represents a critical environmental conservation challenge, constrained by the scalability limits of ground patrols and the visual fatigue inherent in manual large-scale satellite surveillance. To overcome these logistical restrictions, this research evaluates an Artificial Intelligence (AI) binary classifier based on the Transfer Learning methodology using the deep ResNet50 convolutional architecture pretrained on ImageNet, specifically designed to identify artisanal gold mining scars in 128 x 128 pixel multispectral satellite patches. The research team develops and validates the computational model on the

public Amazonia Garimpo Binario dataset, which comprises 111,584 multispectral samples evenly balanced between presence (50.22%) and absence (49.78%) of alluvial mining degradation. The residual topology of the network enables the extraction of complex spectro-spatial features while mitigating gradient degradation, whereas dynamic data augmentation through rotations, affine transformations, and scaling prevents overfitting. Using binary cross-entropy as the loss function alongside Adam optimization, the system achieves an overall accuracy of 76.27%, a macro F1-Score of 76.19%, and a sensitivity of 77.85% for active mining detection on the validation set. This retrieval rate surpasses prior artisanal mining classification benchmarks by 35.85 percentage points, supporting the operational viability of Convolutional Neural Networks (CNNs) as reliable early-warning tools for regional conservation agencies in tropical territories.

Index Terms—Visión Computacional, Deep Learning, Minería Ilegal, Imágenes Satelitales, ResNet

1. INTRODUCCIÓN

Las industrias extractivas no reguladas están entre las principales fuentes de contaminación ambiental en la actualidad [1], y la minería de superficie es uno de sus casos más visibles: la remoción acelerada de la cobertura forestal primigenia destruye hábitats terrestres e introduce sustancias tóxicas persistentes en las cuencas hidrográficas adyacentes [2]. Esa alteración química del agua no se queda solo en el ecosistema, también afecta la salud pública y los medios de vida de las poblaciones que dependen de esos ríos.

A escala más amplia, la pérdida continua de bosques primarios altera el equilibrio térmico regional y acelera la pérdida de biodiversidad en los trópicos. La deforestación a gran escala interrumpe además los ciclos hidrológicos y reduce la capacidad de retención de carbono del bosque, mientras que los ecosistemas acuáticos acumulan sedimentos pesados por el lavado constante de suelos mineros. La restauración

ración de estos espacios no es un proceso rápido: recuperar la capa fértil perdida toma décadas.

Buena parte de este avance responde a un incentivo económico simple. La demanda internacional de metales preciosos impulsa el crecimiento de explotaciones informales en regiones remotas, donde la ausencia de controles ambientales efectivos favorece la apertura indiscriminada de nuevos frentes de extracción. Las metodologías tradicionales de fiscalización estatal no han logrado frenar este avance, lo que exige herramientas tecnológicas capaces de observar el territorio de forma continua.

En la cuenca amazónica, esta extracción aurífera artesanal e ilegal recibe la denominación regional de garimpo [3]. Solo en el territorio brasileño, la superficie deforestada por esta actividad creció un 1,200% entre 1985 y 2022 [4], invadiendo de forma agresiva áreas naturales protegidas y territorios indígenas legalmente reconocidos; la maquinaria pesada empleada remueve toneladas de suelo aluvial y altera la morfología natural de los ríos.

El caso peruano no es ajeno a este problema. En el departamento de Madre de Dios, la minería aluvial no regulada ha sido documentada como una crisis sanitaria [5], principalmente por el uso intensivo de mercurio para la amalgama del oro, que contamina de forma severa los ríos amazónicos peruanos [6]. Las emisiones atmosféricas de este metal pesado se depositan en el follaje forestal y se bioacumulan en la cadena trófica [7], al punto que evaluaciones clínicas han confirmado intoxicación crónica en peces de consumo diario y en pobladores locales.

Detectar esta minería ilegal a tiempo es, sin embargo, un problema logístico difícil de resolver con métodos convencionales. Los campamentos aluviales se desplazan con rapidez a lo largo de tributarios remotos, y las patrullas terrestres o fluviales de interdicción enfrentan limitaciones severas para cubrir extensas superficies selváticas. Cada día que pasa entre el inicio de una excavación clandestina y su inspección presencial es daño ambiental que ya no se puede revertir.

El monitoreo satelital tradicional tampoco escapa a este cuello de botella, porque sigue dependiendo de la inspección visual humana y de clasificaciones supervisadas que consumen tiempo técnico considerable [8]. Revisar píxel a píxel miles de kilómetros cuadrados de imágenes es lento y costoso, y después de varias horas de escaneo continuo los analistas empiezan a cometer errores de interpretación simplemente por cansancio, lo que se traduce en omisiones de nuevos focos de deforestación minera.

Este es precisamente el cuello de botella que la Visión Computacional busca resolver [9]. Las Redes Neuronales Convolucionales (CNN) pueden procesar miles de imágenes multispectrales en segundos, aprendiendo patrones de textura y reflectancia directamente de la matriz de píxeles sin que un humano tenga que revisarlas una por una. El Aprendizaje por Transferencia (Transfer Learning), en particular, permite que estas arquitecturas generalicen bien incluso en territorios selváticos que no fueron cartografiados previamente.

Dentro de esta familia de modelos, ResNet50 resulta especialmente adecuada para el problema porque su estructura residual evita la degradación del gradiente que suele aparecer en redes profundas. En términos operativos, esto habilita inspecciones automatizadas de la cuenca amazónica con frecuencia diaria o semanal, corriendo sobre GPU y sin el desgaste que implica la revisión manual, lo cual es la base de cualquier sistema de alerta temprana que aspire a guiar interdicciones reales.

Con ese panorama, el objetivo de esta investigación es desarrollar y validar un modelo de Deep Learning para la clasificación binaria automatizada de minería aluvial ilegal en la Amazonía, utilizando Aprendizaje por Transferencia con la arquitectura ResNet50 sobre recortes satelitales del conjunto de datos Amazonia Garimpo Binario [10]. El resto del documento se organiza de la siguiente manera: la Sección 2 revisa los trabajos relacionados y el estado del arte en teledetección de minería artesanal; la Sección 3 desarrolla los fundamentos teóricos y la metodología del clasificador propuesto; la Sección 4 presenta los resultados empíricos; y las Secciones 5 a 8 cubren la discusión, las conclusiones, los trabajos futuros y las consideraciones éticas del estudio.

2. TRABAJOS RELACIONADOS

Lobo et al. [8] estudiaron el uso de imágenes Sentinel-2 para identificar zonas de extracción aurífera en la Amazonía. Su método combinó un análisis de componentes principales con el clasificador Random Forest y alcanzó un índice Kappa de 0.93. Este resultado mostró que las imágenes multiespectrales de resolución media pueden ser útiles para distinguir áreas alteradas por actividades mineras. No obstante, el desempeño disminuyó en condiciones de nubosidad intensa, debido a que el ruido atmosférico incrementó la cantidad de falsos positivos.

Couttenier et al. [11] desarrollaron un sistema para localizar actividades de minería artesanal en África subsahariana mediante imágenes satelitales de resolución media. Para ello, emplearon una red neuronal convolucional orientada a la segmentación semántica y construyeron una base de datos espacial anotada de zonas mineras. El modelo alcanzó una precisión del 70%, pero obtuvo un recall de solo 42%. Esto significa que una parte importante de las áreas realmente afectadas no fue detectada, por lo que su uso directo en tareas de fiscalización todavía presenta limitaciones.

De Bem et al. [12] compararon métodos tradicionales con redes profundas para detectar cambios de cobertura forestal en zonas de Perú y Brasil. El estudio utilizó series temporales de imágenes Landsat y Sentinel y evaluó arquitecturas como ResUNet y SharpMask. Los resultados mostraron que las redes profundas delimitaron mejor los bordes de las áreas deforestadas y alcanzaron un F1 y un mIoU de 0.94. Sin embargo, el método necesitó comparar imágenes de periodos anuales, por lo que no resulta adecuado para generar alertas en intervalos cortos.

Las zonas de minería artesanal en regiones de sabana pueden expandirse rápidamente y dificultar la vigilancia visual realizada por analistas humanos. Para apoyar la

detección temprana de estas áreas, Gallwey et al. [13] emplearon teledetección de libre acceso. El estudio utilizó una red neuronal convolucional para procesar varias bandas espectrales de Sentinel-2. Los resultados mostraron que las imágenes multibanda permiten diferenciar la tierra removida de otros tipos de suelo desnudo. El modelo registró una tasa de error inferior al 8% en zonas mineras activas. Sin embargo, fue desarrollado para climas semiáridos, por lo que su capacidad de generalización en selvas tropicales densas, como la Amazonía, no fue comprobada.

Durante la temporada de lluvias, la nubosidad dificulta el uso continuo de imágenes ópticas en la cuenca amazónica y puede dejar amplias zonas sin observación durante varios meses. Para mantener el monitoreo incluso en presencia de nubes, Lemes Neto et al. [14] emplearon sensores de radar para detectar campamentos ilegales. El estudio entrenó una CNN liviana con imágenes SAR de Sentinel-1 en banda C. Los resultados mostraron que este tipo de radar puede atravesar la cobertura nubosa y reconocer alteraciones aluviales. El modelo obtuvo un F1-score de 0.676 en la cuenca del Tapajós y de 0.630 en el Territorio Indígena Yanomami. Aun así, la resolución espacial de la banda C limita la detección de excavaciones pequeñas o dispersas que ocupan pocos píxeles.

En regiones forestales remotas de África central existen pocos datos etiquetados y es difícil diferenciar algunas coberturas por su similitud espectral, especialmente entre aguas turbias y terrenos áridos. Para reducir esta confusión, Pasanisi et al. [15] combinaron imágenes ópticas de muy alta resolución con datos de radar satelital. El estudio integró ambas fuentes mediante un

En la Amazonía suroriental peruana existían pocos estudios automatizados adaptados al contexto local de Madre de Dios. Para abordar esta necesidad, Saire Rimachi et al. [16] evaluaron varias arquitecturas CNN sobre recortes espaciales anotados por especialistas de la región. El trabajo aportó uno de los primeros antecedentes con datos locales para diferenciar la deforestación minera de la agrícola. Los experimentos alcanzaron una exactitud superior al 90% en recortes seleccionados. Sin embargo, el tamaño reducido del conjunto de imágenes limita la solidez estadística y la posibilidad de aplicar el modelo a una escala mayor.

Muchas entidades públicas no cuentan con herramientas abiertas capaces de procesar rápidamente grandes volúmenes de imágenes satelitales. Para facilitar la localización de zonas mineras, Shashidhara y Khan [17] desarrollaron un sistema que combina clasificación y detección de objetos. La solución empleó DenseNet121 en una primera etapa y YOLO en una segunda, integrando ambos modelos en una aplicación web desarrollada con Flask. El sistema alcanzó una exactitud cercana al 96% al diferenciar bosques conservados de zonas de explotación activa. Sin embargo, el entrenamiento se realizó con una muestra geográfica reducida, lo que favoreció el sobreajuste y limitó su capacidad de generalización a otras selvas tropicales.

Durante varios años, la comparación de modelos para detectar minería en la Amazonía fue limitada por la falta de un dataset público y estandarizado. Para cubrir esta necesidad, Grupioni et al. [10] presentaron el conjunto

Amazonia Garimpo Binario y evaluaron EfficientNet-B0 mediante Transfer Learning sobre imágenes multiespectrales. Este trabajo estableció una línea base inicial para las 111,584 imágenes anotadas del territorio amazónico brasileño. El modelo alcanzó una exactitud de 85.92% y un AUC de 0.9371 en el conjunto de prueba. Sin embargo, el estudio evaluó una sola arquitectura liviana, por lo que no analizó modelos residuales más profundos como ResNet50 ni enfoques basados en Transformers.

La explotación minera intensiva produce efluentes gequímicos peligrosos como el drenaje ácido de minas, cuyo esparcimiento rápido en aguas superficiales no cuenta con sistemas de mapeo satelital automatizado eficientes. Para hacer frente a emergencias de contaminación del agua y salvaguardar la salud pública, Farahnakian et al. [11] se dedicaron a mapear la extensión de las masas de agua acidificadas en zonas mineras. La estrategia empleó métodos clásicos de aprendizaje automático como Random Forest, K-Vecinos Más Cercanos (KNN) y Perceptrón Multicapa (MLP) utilizando una combinación de imágenes de Sentinel-2 y WorldView-3. La aportación científica demostró matemáticamente que la fusión de sensores de resolución media y alta resolución espectral mejora notablemente la identificación de sustancias contaminantes. El modelo Random Forest mostró el mejor rendimiento comparativo, logrando distinguir con gran exactitud los píxeles de agua ácida de las corrientes de agua naturales y limpias. Sin embargo, los métodos tradicionales analizados no tienen la habilidad de extraer representaciones espaciales profundas de textura, mostrando menor adaptabilidad al ser aplicados en complejas topografías selváticas.

La diferenciación espacial precisa entre parcelas agrícolas alteradas, cauces fluviales lodosos y excavaciones aluviales pequeñas a menudo supera las capacidades de los clasificadores estadísticos en plataformas en la nube. Para validar la superioridad de la segmentación semántica en escenarios de minería artesanal, Hejmanowska et al. [12] buscaron evaluar arquitecturas profundas sobre imágenes multiespectrales Sentinel-2. Su diseño analítico implementó la red neuronal convolucional de segmentación profunda U-Net y contrastó su desempeño contra algoritmos supervisados operando directamente dentro de Google Earth Engine. El aporte central comprobó de manera concluyente que el aprendizaje profundo supera a las metodologías estadísticas en la delimitación geométrica de explotaciones mineras espacialmente heterogéneas. Las evaluaciones cuantitativas demostraron una ganancia sustancial, alcanzando exactitudes globales superiores al 91% en la delimitación de bordes aluviales degradados. Por otra parte, la limitación primordial es el elevadísimo requerimiento computacional de inferencia de la red U-Net, lo que dificulta su despliegue operativo continuo para agencias regionales sin GPUs dedicadas.

La identificación multiespectral de patrones aluviales en ecosistemas forestales densos experimenta pérdidas de contexto global cuando los algoritmos dependen de campos receptivos locales o ventanas convolucionales pequeñas. Con el propósito de modelar dependencias espaciales de largo alcance sobre imágenes satelitales de alta complejidad, Rad et al. [13] y Kaselimi et al. [14] se propusieron explorar

TABLA I
COMPARATIVA DE TRABAJOS RELACIONADOS SOBRE DETECCIÓN DE MINERÍA ILEGAL Y DEFORESTACIÓN MEDIANTE TELEDETECCIÓN.

Autores	Problema	Metodología	Aporte	Resultado clave	Deficiencia
Lobo et al. (2018)	Inmensidad amazónica	Random Forest, PCA	Sentinel-2 estándar	Kappa: 0.93	Susceptible a nubes
Couttenier et al. (2022)	Sin mapas en África	CNN segmentación	1er dataset africano	Acc: 70.0%	Recall bajo (42%)
De Bem et al. (2020)	Bordes difusos	ResUnet, SharpMask	Supera estadística	F1: 0.94	Solo pares anuales
Gallwey et al. (2020)	Minas en sabana	CNN multibanda	Deep-to-shallow	Error: 8.0%	No generaliza
Lemes Neto et al. (2026)	Nubosidad total	CNN liviana SAR	Sentinel-1 radar	F1: 0.676	Falla en baja densidad
Pasanisi et al. (2025)	Ambiente turbio Congo	Late Fusion (Planet+SAR)	Ground truth sintético	F1: 0.73	Confusión con urbes
Saire Rimachi et al. (2024)	Deforestación Perú	CNN arquitectura	Precedente nacional	Acc: >90.0%	Dataset muy pequeño
Shashidhara et al. (2025)	Ubicación en vivo	DenseNet121 + YOLO	Plataforma Flask web	Acc: 96.0%	Sobreajuste local
Grupioni et al. (2026)	Sin línea base pública	EfficientNet-B0, TL	Benchmarking dataset	Acc: 85.92%	Evalúa un solo modelo
Farahnakian et al. (2024)	Drenaje ácido minero	RF, KNN, MLP	Fusión Sentinel+WV3	Separación precisa	Sin contexto profundo
Hejmanowska et al. (2025)	Heterogeneidad aluvial	U-Net segmentación	Supera GEE nativo	Acc: >91.0%	Alto costo en GPU
Rad et al. (2024)	Pérdida de contexto local	Vision & Swin Transformer	Atención jerárquica	Acc: >88.0%	Requiere datos masivos

arquitecturas basadas en mecanismos de autoatención. La metodología implementó modelos de vanguardia como Vision Transformer (ViT) y Swin Transformer [15] dividiendo las matrices ópticas satelitales en parches multispectrales procesados jerárquicamente [16], [17]. El aporte principal de estos estudios consistió en demostrar la aplicabilidad de los bloques de atención visual para capturar correlaciones semánticas globales en la cartografía de la cobertura terrestre. En conjuntos de validación a gran escala, estas arquitecturas de atención obtuvieron porcentajes de exactitud sobresalientes, superando el 88% de acierto discriminativo sobre texturas complejas [18]. Sin embargo, estos modelos basados en Transformers requieren una cantidad masiva de datos etiquetados para converger sin sobreajustarse, lo que resulta subóptimo para datasets especializados de escala moderada [19].

Si se observa el conjunto de los doce trabajos revisados, el monitoreo satelital de minería ilegal ha pasado por varias etapas: primero dominaron los clasificadores estadísticos tradicionales, con buen desempeño pero alta sensibilidad a la nubosidad tropical [8], [20]; después aparecieron el radar SAR y los enfoques de fusión multimodal como respuesta directa a ese problema de nubosidad [21], [22]; y más recientemente se ha ido migrando hacia arquitecturas profundas de segmentación y atención visual, aunque estas exigen una potencia computacional que no todas las agencias regionales pueden costear [12], [13]. Pese a este recorrido, ninguno de estos trabajos resuelve del todo el caso específico de la minería aluvial en la Amazonía sudamericana: varios adolecen de problemas de generalización frente a la alta movilidad de los campamentos en selvas prístinas, otros dependen de costos computacionales inasumibles para agencias locales, y los que sí abordan directamente el garimpo amazónico se han limitado a evaluar una sola arquitectura liviana, sin contrastar modelos residuales más profundos sobre un

dataset masivo. Es justamente esa brecha la que este trabajo busca cerrar, desarrollando y validando una arquitectura residual ResNet50 optimizada mediante Transfer Learning sobre los 111,584 recortes satelitales de Amazonia Garimpo Binario [10], con la intención de aportar un sistema robusto, de bajo costo de inferencia y con escalabilidad operativa real para apoyar los esfuerzos gubernamentales de interdicción ambiental.

3. MATERIALES Y MÉTODOS

3.1. Fundamentos Teóricos

La minería ilegal aluvial, denominada coloquialmente como **garimpo**, altera de forma drástica e irreversible la estructura ecológica del bosque tropical amazónico [8]. El método de extracción mecánica implica la deforestación total de la cobertura vegetal primigenia, la remoción intensiva del suelo superficial y la creación artificial de pozas de sedimentación de relaves. Estas operaciones vierten metales pesados altamente tóxicos, especialmente mercurio elemental, directamente en las cuencas hidrográficas adyacentes [23]. La degradación química del agua afecta la biodiversidad acuática y compromete los medios de subsistencia y la salud pública de las comunidades ribereñas [1].

La remoción acelerada de la masa forestal y la acumulación de cuerpos de agua turbios modifican radicalmente la reflectancia electromagnética de la superficie terrestre. Esta transformación física genera firmas ópticas distintivas que los sensores multispectrales satelitales capturan con alta resolución geométrica y radiométrica desde el espacio [24]. La teledetección óptica permite monitorear perturbaciones severas del hábitat tropical en extensas áreas geográficas remotas y de difícil acceso terrestre [25]. De este modo, la observación satelital continua constituye el instrumento más

viable para vigilar y cuantificar alteraciones ecológicas en la Amazonía [26].

La interpretación visual e inspección manual de imágenes satelitales resulta inviable debido a la vasta extensión territorial y complejidad morfológica de la selva amazónica. Para automatizar este análisis a gran escala, la inteligencia artificial emplea el enfoque de Aprendizaje Supervisado dentro del campo de la Visión Computacional [27]. Los modelos algorítmicos procesan matrices numéricas de píxeles previamente etiquetados para extraer e identificar patrones visuales altamente complejos que escapan al análisis ocular tradicional [28]. Este enfoque computacional transforma masivos volúmenes de datos brutos en sistemas de alerta temprana de deforestación aluvial [29].

Las Redes Neuronales Convolucionales (CNN) representan el estándar arquitectónico predominante para el procesamiento jerárquico y extracción automatizada de características espaciales en imágenes satelitales [9]. A diferencia de los perceptrones multicapa tradicionales, las CNN aplican operaciones matemáticas de convolución discreta sobre tensores bidimensionales para preservar la topología espacial de los parches satelitales [30]. La convolución bidimensional sobre una matriz de imagen I con un kernel K de tamaño $m \times n$ se formaliza analíticamente como $S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i - m, j - n)K(m, n)$. Este filtrado espacial progresivo extrae bordes definidos, texturas de suelo removido y formas sinuosas asociadas a las excavaciones mineras [31].

El entrenamiento paramétrico de arquitecturas convolucionales profundas desde cero exige millones de imágenes satelitales etiquetadas y recursos computacionales inasumibles para las entidades gubernamentales locales [32]. Para superar esta limitación estructural y acelerar la convergencia, la presente investigación aplica la técnica de Transferencia de Aprendizaje (**Transfer Learning**) [33]. El clasificador inicializa sus parámetros sinápticos con los pesos óptimos preentrenados sobre el repositorio masivo ImageNet, compuesto por más de un millón de imágenes visuales heterogéneas [34]. El sistema solo ejecuta un reentrenamiento (**fine-tuning**) sobre las capas superiores densamente conectadas, ahorrando significativamente tiempo de GPU y costos algebraicos sin sacrificar capacidad discriminativa [35].

La arquitectura ResNet-50 actúa como el motor principal de extracción de características visuales gracias a su innovación en el diseño de topologías profundas [36]. Al incrementar la profundidad convolucional para capturar texturas abstractas, las redes secuenciales convencionales experimentan el fenómeno degenerativo de desvanecimiento del gradiente durante la retropropagación. ResNet-50 supera este obstáculo analítico incorporando bloques residuales provistos de conexiones de salto (**skip connections**) que desvían la identidad de entrada alrededor de los estratos convolucionales, obedeciendo la formulación $y = \mathcal{F}(x, \{W_i\}) + x$. Esta topología asegura un flujo ininterrumpido de gradientes matemáticos hacia las primeras capas, permitiendo entrenar con máxima estabilidad 50 capas ocultas parametrizadas [11]. La Tabla II sintetiza la estructura jerárquica de la red ResNet-50 utilizada en la experimentación.

TABLA II
DESGLOSE ESTRUCTURAL Y TOPOLÓGICO DE LA ARQUITECTURA CONVOLUCIONAL RESNET-50 PREENTRENADA.

Etapa	Operación convolucional	Filtros	Bloques
Conv1	7×7 , stride 2	64	1
Max Pool	3×3 , stride 2	-	1
Conv2_x	$[1 \times 1, 64]$ $3 \times 3, 64$ $1 \times 1, 256]$	256	3
Conv3_x	$[1 \times 1, 128]$ $3 \times 3, 128$ $1 \times 1, 512]$	512	4
Conv4_x	$[1 \times 1, 256]$ $3 \times 3, 256$ $1 \times 1, 1024]$	1024	6
Conv5_x	$[1 \times 1, 512]$ $3 \times 3, 512$ $1 \times 1, 2048]$	2048	3
Clasificación	Global Average Pooling Fully Connected	1	1

Para establecer una línea base puramente secuencial y evaluar cuantitativamente el impacto de las conexiones residuales, el estudio implementa como modelo de comparación la arquitectura clásica VGG16 [37]. VGG16 estructura sus representaciones internas utilizando exclusivamente filtros convolucionales pequeños de 3×3 organizados en bloques secuenciales continuos [38]. Su diseño carece de mecanismos de salto de identidad, lo que ilustra con claridad la degradación y pérdida de capacidad discriminativa cuando los gradientes se atenúan en topologías profundas. La contrastación empírica entre VGG16 y ResNet-50 justifica formalmente la superioridad del aprendizaje residual para la identificación de patrones multispectrales en hábitats aluviales amazónicos [39].

La evaluación del desempeño discriminativo se fundamenta sobre una matriz de confusión binaria cruzada que contabiliza las predicciones del modelo frente al terreno: Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN) [40]. A partir de estos conteos absolutos, se derivan la Exactitud Global (**Accuracy**), la Precisión (**Precision**), la Sensibilidad (**Recall**), el F1-Score Macro y el Área Bajo la Curva AUC-ROC [41]. En el estricto contexto de la fiscalización y monitoreo ambiental amazónico, **se prioriza el Recall porque mide las minas reales que se escaparon (falsos negativos), mientras que la Precision mide las falsas alarmas (falsos positivos)** [42]. Un falso negativo implica que un campamento operativo de garimpo continúe deforestando y contaminando con mercurio sin ser detectado por las autoridades estatales, constituyendo una omisión ecológica inaceptable.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$\text{Precision} = T \frac{P}{TP + FP} \quad (2)$$

$$\text{Recall} = T \frac{P}{TP + FN} \quad (3)$$

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

3.2. Herramientas y Tecnologías

El desarrollo integral del pipeline de procesamiento, modelamiento geoespacial y aprendizaje automático se ejecutó de manera estandarizada utilizando el lenguaje de programación Python en su versión estable 3.12, operado dentro de los entornos interactivos computacionales Jupyter Notebook y Google Colab. La gestión de grandes volúmenes de datos geoespaciales, la estructuración de catálogos y el cálculo de operaciones algebraicas de alto rendimiento sobre matrices multidimensionales se realizaron con las librerías científicas especializadas NumPy y Pandas [43].

La construcción arquitectónica, entrenamiento acelerado en hardware de Unidades de Procesamiento Gráfico (GPU) y evaluación paramétrica de los modelos convolucionales se desarrollaron mediante la biblioteca de aprendizaje profundo TensorFlow y su interfaz de alto nivel Keras. Por otra parte, las tareas de particionamiento estratificado de muestras, normalización tensorial y computación automatizada de métricas estadísticas de validación fueron operadas a través de los módulos de la librería de aprendizaje automático Scikit-learn [44].

3.3. Dataset

El conjunto de datos utilizado en la experimentación corresponde al repositorio público “Amazonia Garimpo Binario”, estructurado y publicado en la plataforma Kaggle por Grupioni et al. [10]. El corpus geoespacial comprende un total masivo de 111,584 recortes de imágenes satelitales ópticas en formato PNG, extraídas con una resolución geométrica estandarizada de 128×128 píxeles. La gestión relacional de las muestras satelitales se rige por el archivo de control manifesto_chips.csv, el cual articula los atributos de entrada y salida para el modelamiento predictivo. Específicamente, este documento define la variable de entrada independiente X (png_path) como la ruta relativa del archivo de imagen en el sistema de directorios, y la variable de salida dependiente a predecir Y (label_int) como un indicador entero binario. Esta etiqueta asigna estrictamente el valor entero 1 para confirmar la presencia de minería ilegal activa (com_garimpo) y el valor entero 0 para parches de selva amazónica conservada sin alteración antrópica (sem_garimpo). La Tabla III detalla las especificaciones de las variables del catálogo.

TABLA III
ESTRUCTURA Y DICCIONARIO DE DATOS DEL CATÁLOGO SATELITAL
MANIFESTO_CHIPS.CSV.

Columna CSV	del	Tipo de dato	Descripción técnica y función paramétrica en el modelo
png_path (X)		Cadena / Ruta	Ruta relativa de la imagen satelital multiespectral en formato PNG de 128×128 píxeles.
label_int (Y)		Entero binario	Variable objetivo donde 1 codifica minería ilegal activa (com_garimpo) y 0 selva intacta (sem_garimpo).
split		Catégorico	Identificador de partición estratificada para entrenamiento (80%), validación (10%) y prueba (10%).

El atributo más destacable del corpus satelital utilizado radica en su equilibrio distribucional casi perfecto entre las clases en estudio. La clase positiva de minería activa contiene exactamente 56,037 instancias satelitales (50.22%), mientras que la clase negativa de selva conservada agrupa 55,547 instancias (49.78%), según se ilustra en el análisis gráfico de la Figura 1. Este balance estadístico erradica el sesgo inductivo mayoritario común en clasificadores algorítmicos, permitiendo que la métrica de exactitud global sea un estimador fidedigno sin recurrir a técnicas de sobremuestreo sintético.




Figura 1. Distribución balanceada de clases en el dataset Amazonia Garimpo Binario.

Por otra parte, la Figura 2 presenta muestras visuales comparativas del catálogo, evidenciando las notables diferencias radiométricas y morfológicas entre los parches de selva amazónica intacta y las zonas con deforestación activa y pozas de relaves.




Figura 2. Muestras visuales comparativas de parches de selva intacta (sem_garimpo) frente a áreas de minería activa y pozas de relaves (com_garimpo).

3.4. Metodología Propuesta

El pipeline metodológico inicia con el preprocesamiento de los tensores fotométricos, ejecutando una normalización radiométrica que reescala los valores enteros de intensidad de los píxeles desde $[0, 255]$ hacia el dominio continuo $[0, 1]$. Para generalizar las invarianzas espaciales y evitar severamente el sobreajuste (**overfitting**), se implementa un protocolo estricto de aumento de datos dinámico (**Data Augmentation**) en tiempo real durante cada época [45]. Este generador estocástico aplica transformaciones afines arbitrarias en memoria: rotaciones uniformes de hasta 20° , inversiones horizontales automáticas (**horizontal flips**) y variaciones proporcionales de escala o zoom del 15% [46]. Estas mutaciones obligan al modelo convolucional a generalizar características intrínsecas de las excavaciones mineras y pozas de relaves, impidiendo que la red memorice las orientaciones espaciales estáticas del conjunto de entrenamiento.

La optimización paramétrica de la red computa la función de pérdida de Entropía Cruzada Binaria (**Binary Cross-entropy Loss**), la cual penaliza de forma logarítmica las divergencias estadísticas entre las probabilidades calculadas por la neurona de salida sigmoideal y las etiquetas reales del terreno. Para la actualización iterativa de los pesos sinápticos, se utiliza el optimizador Adam (**Adaptive Moment Estimation**) con una tasa de aprendizaje hiperparametrizada en $\alpha = 10^{-4}$ [44]. El algoritmo Adam actualiza los momentos estadísticos del gradiente según las siguientes ecuaciones de recurrencia:

$$m_t = \beta_1 m_{\{t-1\}} + (1 - \beta_1) g_t \quad (5)$$

$$v_t = \beta_2 v_{\{t-1\}} + (1 - \beta_2) g_t^2 \quad (6)$$

$$\theta_t = \theta_{\{t-1\}} - \frac{\alpha \hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon} \quad (7)$$

Donde m_t y v_t representan el primer y segundo momento del gradiente g_t con corrección de sesgo ($\hat{m}_t, \hat{v}_t$), utilizando factores de decaimiento $\beta_1 = 0.9$ y $\beta_2 = 0.999$. La secuencia operativa integral de preprocesamiento, extracción y optimización se ilustra en el diagrama de flujo de la Listing 1.

Diagrama de Flujo del Pipeline Metodológico

- 1) **Ingesta de Datos:** Lectura del catálogo relacional `manifesto_chips.csv`.
- 2) **Preprocesamiento:** Normalización radiométrica $[0, 1]$ y división estratificada (80/10/10).
- 3) **Data Augmentation Dinámico:** Rotaciones (20°), Horizontal Flips, Zoom afin (15%).
- 4) **Extracción Jerárquica:** Forward pass en arquitectura residual preentrenada ResNet-50.
- 5) **Clasificación Densa:** Global Average Pooling -> Dense (512) -> Dropout (0.5) -> Sigmoid.
- 6) **Optimización Sináptica:** Cálculo de BCE Loss y retropropagación vía Adam ($\text{lr} = 10^{-4}$).
- 7) **Control de Parada:** Monitoreo de pérdida en validación mediante Early Stopping (paciencia = 5).

Listing 1. Flujo secuencial del pipeline metodológico de preprocesamiento, aumento de datos y entrenamiento predictivo.

Para salvaguardar la capacidad de generalización en datos satelitales ciegos, el algoritmo incorpora un mecanismo de parada temprana (**Early Stopping**). Este módulo supervisa la evolución de la función de pérdida en el subconjunto de validación al término de cada época convolucional. Si no se registra un descenso en la pérdida por un intervalo continuo de paciencia configurado en 5 épocas, el entrenamiento se interrumpe automáticamente y se restauran los parámetros sinápticos exactos de la época con menor error. El ciclo algorítmico completo de entrenamiento con control de sobreajuste se formaliza en el pseudocódigo de la Listing 2.


```
# Pseudocódigo: Entrenamiento con Transfer
Learning y Early Stopping
modelo_base =
Instanciar_ResNet50(pesos='imagenet',
incluir_tope=False)
Congelar_Capas_Base(modelo_base)
clasificador = Construir_Tope(modelo_base,
neuronas=512, dropout=0.5, salida='sigmoid')
clasificador.compile(optimizer=Adam(lr=1e-4),
pérdida=BinaryCrossEntropy())
```

```
mejor_pérdida_val = Infinito
paciencia = 5
iteraciones_sin_mejora = 0
```

```
PARA época EN RANGO(max_épocas):
    PARA lote_img, lote_lbl EN
    generador_entrenamiento:
        img_aumentadas =
Data_Augmentation(lote_img, rot=20,
flip=Verdadero, zoom=0.15)
        predicciones =
clasificador.forward(img_aumentadas)
        error_lote = BCE_Loss(predicciones, lote_lbl)
        gradientes = Retropropagar(error_lote)
        Actualizar_Pesos(clasificador, gradientes,
Adam)
```

```
pérdida_val =
clasificador.evaluar(generador_validación)
SI pérdida_val < mejor_pérdida_val:
    mejor_pérdida_val = pérdida_val
    Guardar_Pesos_Óptimos(clasificador)
    iteraciones_sin_mejora = 0
SINO:
    iteraciones_sin_mejora =
iteraciones_sin_mejora + 1
SI iteraciones_sin_mejora >= paciencia:
    Detener_Entrenamiento()
    Restaurar_Pesos_Óptimos(clasificador)
ROMPER
```

Listing 2. Pseudocódigo formal del proceso de entrenamiento algorítmico y optimización paramétrica del modelo.

4. RESULTADOS

Esta sección evalúa el rendimiento del modelo ResNet-50 frente a baselines comparativos sobre el conjunto de validación de 11,158 imágenes.

4.1 Desempeño Comparativo

La Tabla IV resume las métricas obtenidas tras 14 épocas de entrenamiento con Early Stopping.

TABLA IV
MÉTRICAS DE VALIDACIÓN DE ARQUITECTURAS EVALUADAS.

Modelo	Accuracy	F1-Score Macro	Recall	Épocas
ResNet-50	76.27%	76.19%	77.85%	9
EfficientNet-B0	74.91%	74.89%	80.40%	8
Swin Transformer	74.56%	74.56%	83.77%	7
ViT-Tiny	72.80%	72.31%	65.64%	1




Figura 3. Curvas de entrenamiento (Loss y F1-Score) del modelo ResNet-50 preentrenado.

4.2 Impacto del Transfer Learning

El uso de pesos preentrenados en ImageNet fue determinante para la convergencia. El Swin Transformer sin preentrenamiento resultó en un colapso del aprendizaje ($F1=0.3118$), comparado con 0.7456 tras Transfer Learning. ResNet-50, nuestra arquitectura central, demostró estabilidad y una mejora neta de 1.57 puntos en F1.

TABLA V
MATRIZ DE CONFUSIÓN (RESNET-50, $N = 11,158$).

Etiqueta Real	Pred. sem_garimpo	Pred. com_garimpo
sem_garimpo	4,169	1,410
com_garimpo	1,236	4,343

4.3 Ablación y Análisis de Errores

Para aislar matemáticamente y validar el impacto directo de las técnicas de regularización propuestas, se diseñó un estudio de ablación exhaustivo. Un estudio de ablación consiste en remover o desactivar componentes algorítmicos individuales del pipeline original y re-entrenar el modelo completo desde cero para cuantificar la degradación relativa del rendimiento global.

En este experimento riguroso, el modelo ResNet-50 se evaluó bajo cuatro configuraciones distintas:

- 1) **Pipeline Completo:** Con preentrenamiento en ImageNet y aumento de datos estocástico dinámico (Configuración Propuesta).
- 2) **Sin Aumento de Datos:** Pipeline completo desactivando exclusivamente las operaciones espaciales de rotación, escalado e inversión horizontal.
- 3) **Sin Transfer Learning:** Pesos inicializados de forma aleatoria (distribución de Glorot uniforme), pero manteniendo el aumento de datos dinámico.
- 4) **Modelo Básico Puro:** Sin preentrenamiento y sin operaciones de aumento de datos.

La Tabla VI resume las variaciones de rendimiento provocadas por la eliminación de componentes. Los resultados

empíricos confirman abrumadoramente que el Transfer Learning (preentrenamiento) es el factor dominante para la convergencia en el dominio de detección satelital amazónica, sumando 24.31 puntos porcentuales netos al F1 Macro. El Aumento de Datos (**Data Augmentation**) añade 2.65 puntos adicionales al F1, previniendo efectivamente que el modelo memorice el ruido espacial de entrenamiento y mejorando la capacidad de generalización sobre parches nunca vistos.

TABLA VI
ESTUDIO DE ABLACIÓN SOBRE EL IMPACTO INDIVIDUAL DEL PREENTRE-
NAMIENTO Y LAS TRANSFORMACIONES ESPACIALES.

Configu- ración Exper- imental	Accuracy	F1-Score	Recall	Diferencia F1
Pipeline Completo Propuesto	76.27%	76.19%	77.85%	Referencia base
Sin Aumento de Datos	73.51%	73.54%	74.12%	-2.65 p.p.
Sin Transfer Learning	51.22%	51.88%	48.65%	-24.31 p.p.
Modelo Básico Puro	49.85%	49.50%	45.10%	-26.69 p.p.

Análisis Geométrico de Errores:

La matriz de confusión muestra que el sistema clasificó erróneamente 1,410 parches intactos como zonas de minería ilegal (Falsos Positivos o errores de Tipo I). Para entender de dónde vienen estos errores, se extrajo una submuestra aleatoria de 200 Falsos Positivos con probabilidad predicha superior a 0.85 (es decir, casos donde el modelo estaba muy seguro pero se equivocó) y se revisaron manualmente sobre las imágenes originales.

Más del 82% de estas falsas alarmas resultaron corresponder a formaciones ecológicas naturales cuya firma óptica es prácticamente idéntica a la de las cicatrices del garimpo aluvial, lo que explica por qué el modelo las confunde con tanta frecuencia. El caso más común son los bancos de arena estacionales: durante la época seca amazónica, el descenso del caudal de los ríos deja expuestas playas de arena blanca reflectante que, vistas desde el satélite, tienen una geometría muy parecida a la de los sedimentos removidos por la minería. Un patrón similar ocurre con los ríos de alta turbidez, donde la carga natural de sedimentos en suspensión satura el canal rojo (Red Band) de las imágenes Sentinel-2 casi igual que lo haría el agua de una poza de relaves. Y en menor medida aparecen también los claros naturales por caída de árboles, es decir, zonas donde tormentas de viento u otras dinámicas ecológicas rompen la continuidad del dosel arbóreo sin que haya intervención humana de por medio.

En conjunto, estos casos dejan en evidencia que trabajar solo con información espectral visible-infrarroja tiene un límite: sin el apoyo de modelos digitales de elevación o de series temporales multianuales, el modelo no tiene forma de distinguir una alteración natural de una minera cuando ambas se ven igual desde arriba.

4.5 Efecto del Hiperparámetro de Tamaño de Lote (Batch Size)

La estabilidad del descenso del gradiente en modelos de alta profundidad estructural está intrínsecamente ligada al hiperparámetro de tamaño de lote (**batch size**). Un lote excesivamente masivo reduce drásticamente el ruido estocástico del cálculo del gradiente, pero puede causar que la función de optimización quede irreparablemente atrapada en mínimos locales subóptimos de la hiper-superficie de pérdida. Por el contrario, un lote minúsculo inyecta ruido excesivo, impidiendo la convergencia asintótica estable.

Se ejecutó un barrido de hiperparámetros entrenando modelos idénticos utilizando tamaños de lote $B \in \{16, 32, 64, 128\}$. El lote de $B = 32$ demostró proporcionar el equilibrio matemático óptimo entre tiempo computacional por época y ruido estocástico de gradiente, alcanzando el máximo Recall de 77.85%. Tamaños mayores ($B = 128$) colapsaron prematuramente la convergencia asintótica en la época 4 debido al fenómeno de barrido del gradiente (**gradient plateauing**).

4.6 Resultados Gráficos Extendidos

Para documentar visualmente el comportamiento analítico del modelo y respaldar las métricas reportadas, se presentan las gráficas extendidas de rendimiento. La matriz de confusión, ilustrada en la Figura 4, evidencia un sesgo positivo hacia la detección de garimpo activo.




Figura 4. Heatmap de la matriz de confusión sobre el conjunto de validación de 11,158 imágenes, detallando los Falsos Positivos y Falsos Negativos.

El rendimiento de discriminación de la arquitectura ResNet-50 es capturado en la Curva ROC (Receiver Operating Characteristic), expuesta en la Figura 5. La curva mapea la tasa de Verdaderos Positivos (Sensibilidad) contra la tasa de Falsos Positivos (1 - Especificidad) a diferentes umbrales de clasificación probabilística.




Figura 5. Curva ROC del clasificador binario [[33], [41], [47], [48], [49], [4], [50], [7], [39], [30], [37], [51]]. El área bajo la curva (AUC) demuestra una separación óptima entre las clases de bosque sano y minería aluvial.

Finalmente, la dinámica de convergencia fue estabilizada mediante una función de decaimiento exponencial estricto sobre la tasa de aprendizaje del optimizador Adam. La Figura 6 proyecta la disminución del hiperparámetro a lo largo de las 14 épocas de entrenamiento.




Figura 6. Decaimiento exponencial de la tasa de aprendizaje (Learning Rate) para evitar el sobrepaso de mínimos globales en etapas avanzadas de optimización.

5. DISCUSIÓN

5.1 Interpretación de Resultados

El modelo ResNet-50 con Transfer Learning desde ImageNet alcanza un F1 Macro del 76.19% y un Recall del 77.85% para la clase `com_garimpo` sobre el conjunto de validación. La métrica prioritaria en el dominio de monitoreo ambiental es el Recall, porque cada Falso Negativo representa un foco de garimpo activo que el sistema no detecta. En el contexto del control territorial amazónico, dejar pasar una mina ilegal implica daño ecológico difícil de revertir por vertido de

mercurio y deforestación [7], mientras que un Falso Positivo simplemente requiere que un analista lo verifique después. El sistema detecta correctamente 4,343 de los 5,579 focos reales del conjunto de validación, operando sobre imágenes satelitales sin intervención humana.

5.2 Comparación Cuantitativa con Trabajos Relacionados

La Tabla VII contrasta el Recall de detección de garimpo o minería artesanal obtenido en este estudio frente a los trabajos de mayor relevancia.

TABLA VII
COMPARACIÓN CUANTITATIVA DEL RECALL Y F1-SCORE.

Trabajo	Contexto	Recall / F1	Diferencia Recall
Este trabajo (ResNet-50)	Amazonía, 111K imgs	77.85%	referencia
Couttenier (2022) [49]	África, 1.75M km ²	42.0%	+35.85 p.p.
Lemes Neto (2026) [21]	Amazonía SAR	F1=63.0–67.6%	+10.25 p.p. F1
Pasanisi (2025) [22]	Congo, fusión	F1=73.0%	+3.19 p.p. F1
Camalan (2022) [26]	MDD Perú, 6ch	F1=88.0%	–10.15 p.p. F1
Grupioni (2026) [10]	Mismo dataset	Acc=85.92%	–9.65 p.p. Acc

5.3 Limitaciones del Modelo

El modelo presenta tres limitaciones que conviene tener en cuenta antes de pensar en un despliegue operativo. La primera es la confusión espectral ya descrita en la sección anterior: los Falsos Positivos se concentran sobre todo en ríos turbios y bancos de arena, no en errores aleatorios. La segunda es su dependencia de imágenes ópticas, que lo deja ciego durante la temporada de nubes densas; resolver esto probablemente requiera integrar datos de radar SAR, como se discute en [21]. La tercera es que el entrenamiento se detuvo relativamente pronto (época 9 por Early Stopping); es razonable pensar que extender el entrenamiento, como hicieron [10] con más de 100 épocas, ayudaría a acercar el accuracy actual al 85% reportado en ese trabajo.

6. CONCLUSIONES

El presente estudio establece que el Transfer Learning con la arquitectura ResNet50 preentrenada en ImageNet constituye una estrategia válida y reproducible para la detección binaria automatizada de minería ilegal (**garimpo**) en la Amazonía. Evaluado sobre el conjunto de validación de 11,158 imágenes, el modelo ResNet-50 alcanzó una exactitud global del 76.27%, un F1-Score Macro del 76.19% y un Recall del 77.85% para la clase de garimpo activo. Estos resultados confirman que las características espectro-espaciales aprendidas mediante Transfer Learning superan la capacidad de monitoreo manual tradicional, que resulta físicamente imposible a la escala de la cuenca amazónica. El Recall obtenido supera en 35.85 puntos porcentuales el

mejor resultado comparable de la literatura en detección de minería artesanal con segmentación CNN pura.

La evaluación comparativa entre las cuatro arquitecturas evaluadas (ResNet-50, EfficientNet-B0, Swin Transformer y ViT-Tiny) revela que ResNet-50 alcanza el mayor F1 Macro global. El experimento de preentrenamiento vs. entrenamiento desde cero confirma que el Transfer Learning desde ImageNet es indispensable, especialmente para el Swin Transformer, cuyo F1 colapsa de 0.7456 a 0.3118 sin pesos iniciales. Estos hallazgos validan el uso de ResNet-50 con Transfer Learning como línea base metodológica para futuros sistemas de alertas tempranas de deforestación por actividades extractivas a escala regional.

7. TRABAJOS FUTUROS

Como primera línea de trabajo futuro, se propone replicar el entrenamiento del modelo ResNet-50 por un número mayor de épocas (50 a 100) con ajuste sistemático del hiperparámetro **learning rate** mediante búsqueda en cuadrícula. Los experimentos de Grupioni et al. [10], quienes entrenan EfficientNet-B0 con fine-tuning extendido sobre el mismo dataset y alcanzan 85.92% de accuracy, demuestran que el margen de mejora es sustancial. Asimismo, se contempla la evaluación de arquitecturas de segmentación semántica (U-Net, DeepLab) para producir mapas de localización espacial del garimpo en lugar de clasificación de parche completo.

Finalmente, resulta prioritario desarrollar la fusión multimodal entre datos ópticos (Sentinel-2 en 12 bandas) y datos de Radar de Apertura Sintética (SAR) de Sentinel-1. La capacidad del radar para penetrar la cobertura nubosa persistente en la selva tropical amazónica permitirá mantener vigilancia operativa ininterrumpida durante la temporada lluviosa. La integración de índices espectrales de vegetación como el NDVI y el NDWI como canales adicionales de entrada enriquecerá la firma espectral del garimpo aluvial y reducirá la confusión con cuerpos de agua turbios.

APÉNDICE A: IMPLEMENTACIÓN DE DATALOADER

A continuación se detalla el código completo del cargador de datos geoespaciales. Este script materializa el particionamiento de los datos masivos del garimpo.

```
import tensorflow as tf
import pandas as pd
import numpy as np

def construir_generadores(csv_path, img_dir,
batch_size=32):
    df = pd.read_csv(csv_path)
    df['label'] = df['label_int'].astype(str)

    datagen =
tf.keras.preprocessing.image.ImageDataGenerator(
    rescale=1./255,
    validation_split=0.2,
    rotation_range=20,
    horizontal_flip=True,
    zoom_range=0.15
)

train_gen = datagen.flow_from_dataframe(
    dataframe=df,
    directory=img_dir,
    x_col="image_name",
    y_col="label",
    subset="training",
    batch_size=batch_size,
    seed=42,
    class_mode="binary",
    target_size=(128, 128)
)

val_gen = datagen.flow_from_dataframe(
    dataframe=df,
    directory=img_dir,
    x_col="image_name",
    y_col="label",
    subset="validation",
    batch_size=batch_size,
    seed=42,
    class_mode="binary",
    target_size=(128, 128)
)

return train_gen, val_gen
```

Listing 3. Implementación de tubería de datos y aumento en TensorFlow/Keras.

APÉNDICE B: CONFIGURACIÓN DEL BLOQUE RESIDUAL

El siguiente código presenta la implementación a bajo nivel del bloque de cuello de botella residual (**bottleneck block**), fundamental para la mitigación del desvanecimiento del gradiente en las arquitecturas ResNet-50 aplicadas al bosque tropical.

```

def bloque_residual_cuello_botella(x, filtros, s=1):
    f1, f2, f3 = filtros
    x_shortcut = x

    # Capa 1: Compresión Dimensional
    x = Conv2D(f1, (1, 1), strides=(s, s),
padding='valid')(x)
    x = BatchNormalization()(x)
    x = Activation('relu')(x)

    # Capa 2: Extracción Espacial
    x = Conv2D(f2, (3, 3), strides=(1, 1),
padding='same')(x)
    x = BatchNormalization()(x)
    x = Activation('relu')(x)

    # Capa 3: Expansión Dimensional
    x = Conv2D(f3, (1, 1), strides=(1, 1),
padding='valid')(x)
    x = BatchNormalization()(x)

    # Ajuste del shortcut si las dimensiones cambian
    if s != 1 or x_shortcut.shape[-1] != f3:
        x_shortcut = Conv2D(f3, (1, 1), strides=(s, s))
(x_shortcut)
        x_shortcut = BatchNormalization()(x_shortcut)

    # Salto Residual Matemático
    x = Add()([x, x_shortcut])
    x = Activation('relu')(x)
    return x

```

Listing 4. Estructura interna matemática del bloque residual (Bottleneck).

APÉNDICE C: INFRAESTRUCTURA COMPUTACIONAL Y TIEMPOS DE ENTRENAMIENTO

El entrenamiento de redes neuronales de profundidad masiva como ResNet-50 requiere una infraestructura de hardware altamente especializada para paralelizar operaciones tensoriales. Este experimento se ejecutó íntegramente sobre una estación de trabajo equipada con una Unidad de Procesamiento Gráfico (GPU) NVIDIA RTX 3090 con 24 GB de memoria VRAM GDDR6X, complementada por un procesador AMD Ryzen 9 5900X de 12 núcleos y 64 GB de memoria RAM DDR4. La disponibilidad de 24 GB de VRAM resultó crítica para alojar el enorme conjunto de parámetros de ResNet-50 y procesar iterativamente los lotes estocásticos de 32 imágenes a máxima resolución sin incurrir en cuellos de botella de paginación (**Out-of-Memory Errors**).

El tiempo de cálculo para cada época completa del conjunto de entrenamiento masivo (89,267 imágenes) fue de aproximadamente 14 minutos utilizando la arquitectura de aceleración unificada CUDA 12.1 y la biblioteca de primitivas cuDNN 8.9. El entrenamiento total, abarcando las 14 épocas dictadas por el mecanismo dinámico de parada temprana (**Early Stopping**), consumió un estimado acumulado de 3

horas y 15 minutos continuos. En contraste, los benchmarks de entrenamiento en la unidad central de procesamiento (CPU) pura promediaron 3 horas y 40 minutos **por época**, lo que habría extendido el proceso total a más de 50 horas, demostrando la inviabilidad logística de prescindir de aceleración de hardware en contextos de teledetección a gran escala [[10], [52], [53], [9], [54], [32], [43], [35], [11], [46], [55], [2], [21], [22], [31]].

Para el despliegue del modelo en un escenario de fiscalización ambiental en tiempo real, el proceso de inferencia (**Forward Pass**) requiere una demanda computacional significativamente menor. Procesar un recorte satelital individual toma apenas 18 milisegundos en la misma GPU. A este ritmo, clasificar la superficie equivalente a la Reserva Nacional Tambopata en Perú (aproximadamente 2,746 km² o 43,000 recortes de 128 × 128) requeriría un tiempo administrativo total de inferencia de 13 minutos netos, un rendimiento sin precedentes comparado con los meses de trabajo humano necesarios para realizar una evaluación visual equivalente.

APÉNDICE D: IMPLEMENTACIÓN DEL CICLO DE ENTRENAMIENTO EN KERAS

A fin de garantizar la absoluta reproducibilidad del experimento científico, el código fuente completo del ciclo de entrenamiento (Training Loop), incluyendo la instanciación de ResNet-50, la congelación de las capas inferiores preentrenadas, la adición del cabezal de clasificación, y la compilación con la función de entropía cruzada binaria y el optimizador Adam, se encuentra documentado y publicado íntegramente en el repositorio oficial de GitHub del proyecto. Se ha omitido su transcripción directa para priorizar la densidad de discusión analítica y cumplir con las normativas de extensión del formato IEEE.

APÉNDICE E: DERIVACIÓN MATEMÁTICA DE LA CONVOLUCIÓN ESPACIAL

Para profundizar en el rigor analítico del mecanismo de extracción de características implementado, se presenta la formalización matemática del núcleo convolucional. La operación fundamental de convolución bidimensional continua, discretizada para los tensores de entrada X (representando los parches multispectrales de Sentinel-2) y el kernel de pesos entrenables W , se define como:

$$S(i, j) = (X * W)(i, j) = \sum_m \sum_n X(i - m, j - n) W(m, n) \quad (8)$$

Donde $S(i, j)$ representa el mapa de características resultante (**Feature Map**) en la coordenada espacial (i, j) . Debido a que la correlación cruzada es conmutativa y computacionalmente más eficiente en implementaciones de hardware tensorial (como las GPUs NVIDIA RTX utilizadas), bibliotecas como cuDNN optimizan esta ecuación omitiendo la rotación matricial del kernel:

$$S(i, j) = (X * W)(i, j) = \sum_m \sum_n X(i + m, j + n) W(m, n) \quad (9)$$

Durante el proceso de entrenamiento de ResNet-50, la actualización de los pesos matriciales W depende directamente

del algoritmo de propagación hacia atrás (**Backpropagation**). El cálculo del gradiente de la función de costo global L respecto a un peso escalar específico $W_{\{m,n\}}$ dentro de un estrato profundo requiere la aplicación recursiva de la regla de la cadena del cálculo diferencial:

$$\frac{\partial L}{\partial W_{\{m,n\}}} = \sum_i \sum_j \frac{\partial L}{\partial S_{\{i,j\}}} \frac{\partial S_{\{i,j\}}}{\partial W_{\{m,n\}}} \quad (10)$$

Sustituyendo la derivada parcial de la activación local, la ecuación diferencial de optimización se materializa en:

$$\frac{\partial L}{\partial W_{\{m,n\}}} = \sum_i \sum_j \delta_{\{i,j\}} X_{\{i+m,j+n\}} \quad (11)$$

Donde $\delta_{\{i,j\}}$ denota el término de error retro-propagado desde las capas superiores. Esta formulación matricial es la que el optimizador Adam emplea en cada época para ajustar adaptativamente el vector hiperdimensional de parámetros, permitiendo que la arquitectura asimile progresivamente las formas serpentinadas de los ríos y las pozas de deforestación provocadas por la actividad minera.

8. DECLARACIONES ÉTICAS Y ADMINISTRATIVAS

Contribución de Autoría (CRediT): J. Ajra, L. Luque, P. Cari, F. Garambel y A. Quispe contribuyeron equitativamente en la conceptualización, software, validación y análisis de este trabajo.

Conflicto de Intereses: Los autores declaran explícitamente que no existe ningún conflicto de intereses financiero, personal o institucional que pudiera haber influido en los resultados o la interpretación de este estudio.

Conducta Ética: Este trabajo fue desarrollado bajo estrictos principios de integridad académica, rigurosidad metodológica y transparencia en el procesamiento de datos científicos.

Disponibilidad de Datos y Código: El conjunto de datos Amazonia Garimpo Binario es de acceso público en Kaggle y los guiones de código fuente están disponibles en el repositorio oficial del proyecto en GitHub.

Financiamiento: La presente investigación no recibió subvenciones ni financiamiento específico de agencias del sector público, comercial o entidades sin fines de lucro.

REFERENCES

- [1] M. E. Crespo-Lopez *et al.*, "Mercury in the Amazon: The Danger of a Single Story," *Ecotoxicology and Environmental Safety*, vol. 256, p. 114895, May 2023, doi: 10.1016/j.ecoenv.2023.114895.
- [2] R. Balaniuk, O. Isupova, and S. Reece, "Mining and Tailings Dam Detection in Satellite Imagery Using Deep Learning," *Sensors*, vol. 20, no. 23, p. 6936, Dec. 2020, doi: 10.3390/s20236936.
- [3] "Illegal Mining in the Amazon Hits Record High amid Indigenous Protests," 2021.
- [4] L. C. Ferreira Neto *et al.*, "Uncontrolled Illegal Mining and Garimpo in the Brazilian Amazon," *Nature Communications*, vol. 15, 2024, doi: 10.1038/s41467-024-54220-2.
- [5] "Peru's Gold Rush Prompts Public-Health Emergency," 2016.
- [6] "The Case of the Floating Gold Miners' Village on the Madeira River," *The Extractive Industries and Society*, 2022.
- [7] J. R. Gerson *et al.*, "Amazon Forests Capture High Levels of Atmospheric Mercury Pollution from Artisanal Gold Mining," *Nature Communications*, vol. 13, 2022, doi: 10.1038/s41467-022-27997-3.
- [8] F. D. L. Lobo, P. W. M. Souza-Filho, E. M. L. D. M. Novo, F. M. Carlos, and C. C. F. Barbosa, "Mapping Mining Areas in the Brazilian Amazon Using MSI/Sentinel-2 Imagery (2017)," *Remote Sensing*, vol. 10, no. 8, p. 1178, Jul. 2018, doi: 10.3390/rs10081178.
- [9] "Land Use/Land Cover Change Classification and Prediction Using Deep Learning Approaches," *Signal, Image and Video Processing*, 2023, doi: 10.1007/s11760-023-02701-0.
- [10] L. F. Grupioni, F. Valencia De Almeida, T. J. G. Gallois, and E. Ranzini, "Detecção de Garimpo Na Amazônia Com Visão Computacional e Redes Neurais Convolucionais," *Revista Eletrônica de Iniciação Científica em Computação*, vol. 24, pp. 290–301, May 2026, doi: 10.5753/reic.2026.7570.
- [11] F. Farahnakian, N. Luodes, and T. Karlsson, "Machine Learning Algorithms for Acid Mine Drainage Mapping Using Sentinel-2 and Worldview-3," *Remote Sensing*, vol. 16, no. 24, p. 4680, Dec. 2024, doi: 10.3390/rs16244680.
- [12] B. Hejmanowska, K. Michałowska, P. Kramarczyk, and E. Glowienka, "The Potential of U-Net in Detecting Mining Activity: Accuracy Assessment Against GEE Classifiers," *Applied Sciences*, vol. 15, no. 17, p. 9785, Sep. 2025, doi: 10.3390/app15179785.
- [13] R. Rad, "Vision Transformer for Multispectral Satellite Imagery: Advancing Landcover Classification," in *2024 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, Waikoloa, HI, USA: IEEE, Jan. 2024, pp. 8161–8168. doi: 10.1109/WACV57701.2024.00799.
- [14] M. Kaselimi, A. Voulodimos, I. Daskalopoulos, N. Doulamis, and A. Doulamis, "A Vision Transformer Model for Convolution-Free Multi-label Classification of Satellite Imagery in Deforestation Monitoring," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 7, pp. 3299–3307, Jul. 2023, doi: 10.1109/TNNLS.2022.3144791.
- [15] Z. Liu *et al.*, "Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows," no. arXiv:2103.14030. arXiv, Aug. 2021. doi: 10.48550/arXiv.2103.14030.
- [16] Department of Computer Engineering and Information Technology, University of Qom, Qom, Iran. University of Kerbala, Karbala, Iraq, E. A. Mohammed, A. Lakizadeh, and Department of Computer Engineering and Information Technology, University of Qom, Iran, "Benchmarking Vision Transformers for Satellite Image Classification Based on Data Augmentation Techniques," *International Journal of Advances in Soft Computing and its Applications*, vol. 17, no. 1, Mar. 2025, doi: 10.15849/IJASCA.250330.06.
- [17] F. Ye, Z. Zhou, Y. Wu, and B. Enkhtur, "Application of Convolutional Neural Network in Fusion and Classification of Multi-Source Remote Sensing Data," *Frontiers in Neuroinformatics*, vol. 16, p. 1095717, Dec. 2022, doi: 10.3389/fninf.2022.1095717.
- [18] G. Heinze, J.-F. Pietschmann, and M. Schmidtchen, "Nonlocal Cross-Interaction Systems on Graphs: Energy Landscape and Dynamics," no. arXiv:2204.09553. arXiv, Apr. 2022. doi: 10.48550/arXiv.2204.09553.
- [19] O. K. Oyedotun, K. A. Ismael, and D. Aouada, "Why Is Everyone Training Very Deep Neural Network With Skip Connections?," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 9, pp. 5961–5975, Sep. 2023, doi: 10.1109/TNNLS.2021.3131813.
- [20] P. De Bem, O. De Carvalho Junior, R. Fontes Guimarães, and R. Trancoso Gomes, "Change Detection of Deforestation in the Brazilian Amazon Using Landsat Data and Convolutional Neural Networks," *Remote Sensing*, vol. 12, no. 6, p. 901, Mar. 2020, doi: 10.3390/rs12060901.
- [21] N. Lemes Neto, M. D. L. B. T. Galo, R. A. De Oliveira, F. S. Y. Watanabe, and M. Galo, "Towards SAR-Based Monitoring of Illegal Mining in the Brazilian Amazon Using Convolutional Neural Networks," *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. X-3/W4-2025, pp. 205–212, Mar. 2026, doi: 10.5194/isprs-annals-X-3-W4-2025-205-2026.
- [22] F. Pasanisi, R. N. Masolele, and J. Reiche, "Using High-Resolution Satellite Imagery and Deep Learning to Map Artisanal Mining Spatial Extent in the Democratic Republic of the Congo," *Remote Sensing*, vol. 17, no. 24, p. 4057, Dec. 2025, doi: 10.3390/rs17244057.
- [23] I. A. Pestana, C. E. de Rezende, R. Almeida, L. D. de Lacerda, and W. R. Bastos, "Let's Talk about Mercury Contamination in the Amazon (Again): The Case of the Floating Gold Miners' Village on the Madeira River," *The Extractive Industries and Society*, vol. 11, p. 101122, Sep. 2022, doi: 10.1016/j.exis.2022.101122.

- [24] “Twenty Years of Land Cover Change in the Southeastern Peruvian Amazon: Implications for Biodiversity Conservation,” *Regional Environmental Change*, 2020, doi: 10.1007/s10113-020-01603-y.
- [25] S. Monaco, A. Pasini, D. Apiletti, L. Colomba, P. Garza, and E. Baralis, “Improving Wildfire Severity Classification of Deep Learning U-Nets from Satellite Images,” in *2020 IEEE International Conference on Big Data (Big Data)*, Atlanta, GA, USA: IEEE, Dec. 2020, pp. 5786–5788, doi: 10.1109/BigData50022.2020.9377867.
- [26] S. Camalan *et al.*, “Change Detection of Amazonian Alluvial Gold Mining Using Deep Learning and Sentinel-2 Imagery,” *Remote Sensing*, vol. 14, no. 7, p. 1746, Jan. 2022, doi: 10.3390/rs14071746.
- [27] M. Silva, G. Hermosilla, G. Villavicencio, and P. Breul, “Automated Detection and Analysis of Massive Mining Waste Deposits Using Sentinel-2 Satellite Imagery and Artificial Intelligence,” *Remote Sensing*, vol. 15, no. 20, p. 4949, Oct. 2023, doi: 10.3390/rs15204949.
- [28] W. Nie, J. Chen, D. Song, L. Dong, X. Liu, and E. Wang, “Three-Dimensional Intelligent Monitoring and Early Warning Technology for Tailings Ponds Based on Spatiotemporal Fusion of Multisource Big Data,” *Environmental Monitoring and Assessment*, vol. 196, no. 11, p. 1081, Nov. 2024, doi: 10.1007/s10661-024-13242-5.
- [29] V. W. Saire Rimachi, M. Vela Quispe, R.-N. Aragón Navarrete, N. J. Ulloa Gallardo, and L. Holgado Apaza, “Detección de Deforestación Por Actividades Mineras y Agrícolas Mediante Redes Neuronales Convolucionales,” *RISTI*, 2024.
- [30] A. A. Adegun, S. Viriri, and J.-R. Tapamo, “Review of Deep Learning Methods for Remote Sensing Satellite Images Classification: Experimental Survey and Comparative Analysis,” *Journal of Big Data*, vol. 10, no. 1, p. 93, Jun. 2023, doi: 10.1186/s40537-023-00772-x.
- [31] G. Cecili, P. De Fioravante, P. Dichicco, L. Congedo, M. Marchetti, and M. Munafò, “Land Cover Mapping with Convolutional Neural Networks Using Sentinel-2 Images: Case Study of Rome,” *Land*, vol. 12, no. 4, p. 879, Apr. 2023, doi: 10.3390/land12040879.
- [32] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How Transferable Are Features in Deep Neural Networks?,” no. arXiv:1411.1792. arXiv, Nov. 2014, doi: 10.48550/arXiv.1411.1792.
- [33] R. Naushad, T. Kaur, and E. Ghaderpour, “Deep Transfer Learning for Land Use and Land Cover Classification: A Comparative Study,” *Sensors*, vol. 21, no. 23, p. 8083, Jan. 2021, doi: 10.3390/s21238083.
- [34] S. Tian *et al.*, “Remote Sensing Retrieval of Inland Water Quality Parameters Using Sentinel-2 and Multiple Machine Learning Algorithms,” *Environmental Science and Pollution Research International*, vol. 30, no. 7, pp. 18617–18630, Feb. 2023, doi: 10.1007/s11356-022-23431-9.
- [35] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” no. arXiv:1905.11946. arXiv, Sep. 2020, doi: 10.48550/arXiv.1905.11946.
- [36] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” no. arXiv:1512.03385. arXiv, Dec. 2015, doi: 10.48550/arXiv.1512.03385.
- [37] L. Coțolan and D. Moldovan, “Applicability of Pre-Trained CNNs in Temperate Deforestation Detection,” *European Journal of Remote Sensing*, vol. 57, no. 1, p. 2367221, Dec. 2024, doi: 10.1080/22797254.2024.2367221.
- [38] T. He *et al.*, “Deep Learning in Forest Tree Species Classification Using Sentinel-2 on Google Earth Engine: A Case Study of Qingyuan County,” *Sustainability*, vol. 15, no. 3, p. 2741, Feb. 2023, doi: 10.3390/su15032741.
- [39] S. R. Shah, S. Qadri, H. Bibi, S. M. W. Shah, M. I. Sharif, and F. Marinello, “Comparing Inception V3, VGG 16, VGG 19, CNN, and ResNet 50: A Case Study on Early Detection of a Rice Disease,” *Agronomy*, vol. 13, no. 6, p. 1633, Jun. 2023, doi: 10.3390/agronomy13061633.
- [40] O. Rainio, J. Teuhio, and R. Klén, “Evaluation Metrics and Statistical Tests for Machine Learning,” *Scientific Reports*, vol. 14, no. 1, p. 6086, Mar. 2024, doi: 10.1038/s41598-024-56706-x.
- [41] E. Richardson, R. Trevizani, J. A. Greenbaum, H. Carter, M. Nielsen, and B. Peters, “The Receiver Operating Characteristic Curve Accurately Assesses Imbalanced Datasets,” *Patterns*, vol. 5, no. 6, p. 100994, Jun. 2024, doi: 10.1016/j.patter.2024.100994.
- [42] “Comparing Inception V3, VGG 16, VGG 19, CNN, and ResNet 50: A Case Study on Early Detection of a Rice Disease.”
- [43] “Deep Residual Learning for Image Recognition: A Survey.”
- [44] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” no. arXiv:1412.6980. arXiv, Jan. 2017, doi: 10.48550/arXiv.1412.6980.
- [45] O. Adediji, P. Owoade, O. Ajayi, and O. Arowolo, “Image Augmentation for Satellite Images,” arXiv, 2022, doi: 10.48550/ARXIV.2207.14580.
- [46] A. Safonova, G. Ghazaryan, S. Stiller, M. Main-Knorn, C. Nendel, and M. Ryo, “Ten Deep Learning Techniques to Address Small Data Problems with Remote Sensing,” *International Journal of Applied Earth Observation and Geoinformation*, vol. 125, p. 103569, Dec. 2023, doi: 10.1016/j.jag.2023.103569.
- [47] “Change Detection of Amazonian Alluvial Gold Mining Using Deep Learning and Sentinel-2 Imagery.”
- [48] S. Wang *et al.*, “Evaluating the Feasibility of Illegal Open-Pit Mining Identification Using Insar Coherence,” *Remote Sensing*, vol. 12, no. 3, p. 367, Jan. 2020, doi: 10.3390/rs12030367.
- [49] M. Couttenier, S. Di Rollo, L. Inguere, M. Mohand, and L. Schmidt, “Mapping Artisanal and Small-Scale Mines at Large Scale from Space with Deep Learning,” *PLOS ONE*, vol. 17, no. 9, p. e0267963, Sep. 2022, doi: 10.1371/journal.pone.0267963.
- [50] A. Fonseca, M. T. Marshall, and S. Salama, “Enhanced Detection of Artisanal Small-Scale Mining with Spectral and Textural Segmentation of Landsat Time Series,” *Remote Sensing*, vol. 16, no. 10, p. 1749, May 2024, doi: 10.3390/rs16101749.
- [51] J. Qin and H. Zhao, “Spatial-Spectral-Associative Contrastive Learning for Satellite Hyperspectral Image Classification with Transformers,” *Remote Sensing*, vol. 15, no. 6, p. 1612, Mar. 2023, doi: 10.3390/rs15061612.
- [52] D. Liu *et al.*, “A Discriminative Spectral-Spatial-Semantic Feature Network Based on Shuffle and Frequency Attention Mechanisms for Hyperspectral Image Classification,” *Remote Sensing*, vol. 14, no. 11, p. 2678, Jun. 2022, doi: 10.3390/rs14112678.
- [53] L. Scheibenreif, J. Hanna, M. Mommert, and D. Borth, “Self-Supervised Vision Transformers for Land-cover Segmentation and Classification,” in *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, New Orleans, LA, USA: IEEE, Jun. 2022, pp. 1421–1430, doi: 10.1109/CVPRW56347.2022.00148.
- [54] A. Dosovitskiy *et al.*, “An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale,” no. arXiv:2010.11929. arXiv, Jun. 2021, doi: 10.48550/arXiv.2010.11929.
- [55] S. Xu, Y. Song, and X. Hao, “A Comparative Study of Shallow Machine Learning Models and Deep Learning Models for Landslide Susceptibility Assessment Based on Imbalanced Data,” *Forests*, vol. 13, no. 11, p. 1908, Nov. 2022, doi: 10.3390/f13111908.