

Detección de Riesgo de Minería Ilegal en la Amazonía usando Visión Computacional

Jeans Anthony Ajra Huacso
*Escuela Profesional de Ingeniería de
Sistemas*
Universidad Nacional de San Agustín
Arequipa, Perú
jajra@unsa.edu.pe

Paul Andree Cari Lipe
*Escuela Profesional de Ingeniería de
Sistemas*
Universidad Nacional de San Agustín
Arequipa, Perú
pcaril@unsa.edu.pe

Fernando Garambel Marín
*Escuela Profesional de Ingeniería de
Sistemas*
Universidad Nacional de San Agustín
Arequipa, Perú
fgarambel@unsa.edu.pe

Luis Guillermo Luque Condori
Escuela Profesional de Ingeniería de Sistemas
Universidad Nacional de San Agustín
Arequipa, Perú
lluquecon@unsa.edu.pe

Alexandra Raquel Quispe Arrate
Escuela Profesional de Ingeniería de Sistemas
Universidad Nacional de San Agustín
Arequipa, Perú
aquispearr@unsa.edu.pe

Abstract—El proceso de detección manual de minería ilegal mediante imágenes satelitales presenta grandes desafíos de escalabilidad y fatiga visual. En este artículo, presentamos una arquitectura basada en Redes Neuronales Convolucionales (CNN) y Transfer Learning con ResNet50 para clasificar la presencia de garimpo en la Amazonía, superando los métodos estadísticos convencionales. El modelo se entrena sobre el dataset Amazonia Garimpo Binario (111,584 imágenes de 128×128 píxeles) y se evalúa con exactitud, precisión, recall, F1-score y AUC-ROC. Los resultados demuestran la viabilidad del enfoque para el monitoreo automatizado de la minería ilegal a escala regional.

Index Terms—Visión Computacional, Deep Learning, Minería Ilegal, Imágenes Satelitales, ResNet

I. INTRODUCCIÓN

La degradación ambiental representa una de las mayores crisis del siglo XXI. Las actividades industriales extractivas generan contaminación del suelo, el agua y el aire a escala regional y global. La minería ocupa un lugar central entre estas actividades, dado que combina la destrucción directa de la cobertura vegetal con la liberación de sustancias tóxicas al entorno. Las consecuencias se manifiestan en la pérdida de biodiversidad, el deterioro de fuentes hídricas y el daño directo a las comunidades humanas que habitan los territorios afectados.

La cuenca amazónica constituye el mayor repositorio de biodiversidad terrestre del planeta. Sus bosques regulan el ciclo del agua, almacenan carbono y sostienen a cientos de pueblos indígenas. El avance de la minería ilegal sobre estos territorios protegidos alcanzó niveles históricos durante el período 2019–2022, según análisis de 36 años de imágenes satelitales [1]. Las operaciones ilegales despajan la vegetación y contaminan los ríos con mercurio, destruyendo ecosistemas que tardan décadas en recuperarse.

El término “garimpo” designa la minería artesanal e ilegal de pequeña escala que predomina en la cuenca amazónica. Este tipo de extracción creció en un 1,200% en Brasil entre

1985 y 2022, pasando de 218 km² a 2,627 km² [2]. Más del 91% de esta actividad se concentra en la Amazonía, y al menos el 77% de los sitios registrados en 2022 exhiben indicios explícitos de ilegalidad. Las tres tierras indígenas más afectadas, Kayapo, Munduruku y Yanomami, concentran más del 90% del garimpo dentro de territorios legalmente protegidos.

El problema no se circunscribe a Brasil. En Perú, la región Madre de Dios fue declarada en emergencia sanitaria de 60 días a causa de la contaminación por mercurio generada por la minería aurífera no regulada [3]. Los estudios científicos confirmaron altos niveles de mercurio en peces locales y en la sangre de las poblaciones que los consumen como fuente primaria de proteínas. La emergencia evidenció la incapacidad del Estado para controlar la expansión minera mediante mecanismos de inspección tradicionales.

Las operaciones de garimpo presentan una característica que las hace especialmente difíciles de controlar: la movilidad. Los campamentos mineros se desplazan constantemente por los ríos y quebradas para evadir a las autoridades [4]. Esta capacidad de movimiento hace inviable la detección mediante patrullaje terrestre o inspecciones periódicas. El tiempo transcurrido entre una operación y su eventual detección tradicional permite que el daño ambiental se vuelva irreversible.

Las emisiones de mercurio procedentes de la minería artesanal superan a la combustión de carbón como la mayor fuente global de este metal tóxico [5]. Los bosques intactos ubicados en la proximidad de zonas mineras interceptan grandes cantidades de mercurio particulado y gaseoso, acumulándolo en suelos, biomasa y fauna silvestre. Los estudios documentan acumulación en aves residentes de áreas protegidas, demostrando que la contaminación trasciende el área de extracción directa. Este fenómeno compromete los esfuerzos de conservación en los ecosistemas más biodiversos de la Amazonía [6].

La deforestación causada por la minería aurífera en Madre de Dios, Perú, avanza a una velocidad que desborda la capacidad de respuesta institucional [7]. Los análisis de cambio de cobertura terrestre durante veinte años en la Amazonía suroriental peruana confirman una pérdida sostenida de bosque atribuible a actividades extractivas [8]. La extensión de los territorios afectados, que supera los miles de kilómetros cuadrados, hace que el monitoreo terrestre sea físicamente imposible para los recursos humanos disponibles. No existe ningún mecanismo convencional que permita detectar nuevos focos mineros en tiempo real sobre superficies de esa magnitud.

El uso de imágenes satelitales multispectrales Sentinel-2 permitió mapear 1,084.7 km² de áreas mineras en 13 regiones del Amazonas brasileño [9]. Sin embargo, este enfoque requirió clasificación supervisada manual, edición vectorial intensiva y validación por expertos con imágenes de alta resolución. El proceso consume tiempo humano considerable y no escala a la velocidad con la que la minería avanza. La fatiga visual y el sesgo del analista introducen errores que reducen la confiabilidad del monitoreo continuo.

La Inteligencia Artificial, y en particular el Deep Learning, resuelve los problemas de escalabilidad y velocidad que limitan el monitoreo humano de la Amazonía. Los modelos de clasificación basados en redes neuronales convolucionales (CNN) aprenden a distinguir patrones de deforestación y actividad minera directamente de píxeles satelitales [10]. La Visión Computacional aplicada a imágenes Sentinel-2 permite procesar miles de kilómetros cuadrados en minutos. El Transfer Learning sobre arquitecturas como ResNet permite alcanzar alta exactitud incluso con conjuntos de datos de tamaño moderado.

El presente trabajo propone un sistema de clasificación binaria basado en CNN con Transfer Learning (ResNet50) para detectar la presencia de garimpo en imágenes satelitales de la Amazonía, usando el dataset “Amazonia Garimpo Binario” de Kaggle con 111,584 imágenes etiquetadas. El resto del informe se organiza de la siguiente manera: la Sección 2 presenta los trabajos relacionados; la Sección 3 expone los fundamentos teóricos; la Sección 4 describe la metodología y los experimentos; la Sección 5 reporta los resultados; y la Sección 6 presenta las conclusiones.

II. TRABAJOS RELACIONADOS

La clasificación de imágenes satelitales de alta resolución con métodos convencionales presenta limitaciones severas por la complejidad espectral y textural de los datos. Adegun et al. [11] se propusieron evaluar y comparar arquitecturas de Deep Learning para la clasificación eficiente de imágenes de teledetección. El aporte central es una revisión experimental sistemática que establece el estado del arte en clasificación satelital con CNN y Vision Transformers. La metodología evaluó ResNet, DenseNet, EfficientNet, VGG e InceptionV3 sobre tres datasets públicos: EuroSAT, UCMerced-LandUse y NWPU-RESISC45. Los modelos alcanzaron métricas prometedoras de exactitud, precisión, recall y F1-score en todos los conjuntos evaluados. La limitación principal es que los

benchmarks no representan ecosistemas tropicales ni escenarios de minería ilegal.

La identificación automática de minas y presas de relaves en vastos territorios nacionales excede la capacidad de inspección gubernamental convencional. Balaniuk et al. [12] plantearon como objetivo detectar a escala nacional todas las minas y presas de relaves en Brasil usando Deep Learning de bajo costo. El aporte principal es la demostración de que herramientas gratuitas pueden descubrir concesiones mineras ilegales a escala nacional. La metodología empleó Fully Convolutional Neural Networks sobre imágenes Sentinel-2 procesadas en Google Earth Engine. El sistema descubrió 263 minas sin concesión oficial en el territorio brasileño. La deficiencia es que el modelo no distingue entre tipos de minería ni clasifica las operaciones como legales o ilegales.

La detección de cambios en lagunas de minería de oro aluvial en la Amazonía enfrenta interferencia atmosférica y dificultades de clasificación multiclase. Camalan et al. [13] propusieron un sistema de detección de cambios binarios y multiclase en zonas de minería aurífera en la región Madre de Dios, Perú. El aporte principal es el modelo supervisado E-ReCNN con emparejamiento de histogramas y métricas $L_a \times b_a$ que mejora la robustez ante efectos atmosféricos. La metodología combina Sentinel-2 de 6 canales con un dataset etiquetado construido con expertos de dominio. El modelo alcanzó Kappa de 0.92 y F1 de 0.88 en la región focal de Madre de Dios. La limitación reportada es la dependencia de condiciones atmosféricas estables para la corrección espectral eficaz.

La minería artesanal y de pequeña escala opera de forma mayoritariamente informal en África, sin monitoreo gubernamental efectivo. Couttenier et al. [14] se propusieron construir el primer mapa masivo de minería artesanal sobre 1.75 millones de km² en 13 países de África Occidental. El aporte es el primer dataset masivo de minería artesanal en esa región, combinado con un método de segmentación CNN escalable a nivel continental. La metodología utilizó una CNN de segmentación sobre imágenes satelitales de resolución media del conjunto Sub-Tropical West Africa. El modelo alcanzó 70% de precisión con 42% de recall en la detección de sitios mineros. La deficiencia es el recall moderado, que implica subestimación de la actividad real y limita el uso del mapa para fiscalización.

La detección de deforestación en la Amazonía requiere comparar pares de imágenes temporales, tarea que los métodos clásicos realizan con baja precisión geométrica. De Bem et al. [15] compararon arquitecturas CNN contra algoritmos clásicos de Machine Learning para detectar deforestación entre pares de imágenes Landsat anuales en Brasil. El aporte principal es la demostración de que ResUnet supera a los métodos estadísticos con bordes definidos y sin requerir postprocesamiento. La metodología utilizó pares de imágenes Landsat de 2017–2018 y 2018–2019, evaluados con Kappa, F1 e Intersección sobre Unión. ResUnet alcanzó Kappa, F1 e mIoU de 0.94 en ambas secuencias temporales. La limitación es la dependencia de pares anuales de imágenes, lo que impide detección en tiempo casi real.

La minería artesanal de pequeña escala en Ghana se expande sin control, sin sistemas automatizados de monitoreo que alerten a las autoridades. Gallwey et al. [16] desarrollaron un sistema CNN multispectral basado en Sentinel-2 para detectar minería artesanal de pequeña escala en Ghana. El aporte principal es la primera aplicación de CNN multibanda a la detección de minería artesanal superficial en el contexto africano. La metodología denominada “deep learning to shallow mining” aprovechó múltiples bandas espectrales de Sentinel-2 para discriminar zonas mineras. El modelo identificó zonas mineras activas con información espectral de libre acceso. La deficiencia es la falta de generalización a ecosistemas tropicales distintos a la sabana ghanesa.

La cobertura nubosa persistente en la Amazonía invalida el uso de sensores ópticos para el monitoreo continuo en períodos lluviosos. Lemes Neto et al. [17] propusieron explorar imágenes SAR de banda C (Sentinel-1) con una CNN liviana para detectar minería ilegal bajo cobertura nubosa total. El aporte diferencial es la demostración de que imágenes de radar son una alternativa viable a los sensores ópticos para monitoreo amazónico en cualquier condición climática. La metodología entrenó la CNN en 7 escenas Sentinel-1 de la cuenca Tapajós y evaluó la generalización en el Territorio Indígena Yanomami. El modelo logró F1-score de 0.676 en Tapajós y 0.630 en Yanomami. La deficiencia identificada es la dificultad para capturar patrones mineros de baja densidad y estructuras periféricas pequeñas.

La minería artesanal en la República Democrática del Congo opera en zonas sin cartografía confiable y con escasez de datos de entrenamiento etiquetados. Pasanisi et al. [18] propusieron mapear la extensión espacial de la minería artesanal en el Congo mediante fusión de imágenes de alta resolución con datos SAR. El aporte principal es el enfoque Late Fusion Planet-NICFI más Sentinel-1, que mejora la discriminación entre agua y zonas mineras respecto a métodos ópticos puros. La metodología generó un pseudo-ground truth desde puntos de referencia mediante clustering, masking y refinamiento manual. El modelo Late Fusion alcanzó precisión de 71%, recall de 75% y F1 de 73%. La deficiencia es la dificultad para distinguir sitios mineros de áreas urbanizadas.

La deforestación por actividades mineras en la Amazonía peruana no cuenta con herramientas CNN automatizadas en idioma español adaptadas al contexto latinoamericano. Saire Rimachi et al. [19] aplicaron redes neuronales convolucionales para detectar deforestación causada por actividades mineras y agrícolas en la Amazonía peruana. El aporte es un precedente metodológico directo para el contexto latinoamericano, con datos propios de Perú. La metodología empleó arquitecturas CNN sobre imágenes satelitales anotadas de la región amazónica peruana. El modelo demostró capacidad de detectar patrones de deforestación diferenciando causas antrópicas. La limitación principal es el tamaño reducido del conjunto de datos de entrenamiento.

Las agencias gubernamentales carecen de herramientas en tiempo real para detectar y localizar espacialmente zonas de minería ilegal en imágenes satelitales. Shashidhara y Khan

[20] propusieron un sistema de doble etapa que combina clasificación e identificación espacial de zonas mineras ilegales. El aporte es la integración de CNN con DenseNet121 para clasificación y YOLO para localización espacial en una sola plataforma web desplegable. La metodología implementó un pipeline de preprocesamiento seguido de clasificación CNN y detección YOLO, desplegado en Flask. El sistema logró alta exactitud en la clasificación binaria entre zonas de bosque y zonas de minería ilegal. La cobertura geográfica del dataset fue reducida, limitando la generalización a otros territorios.

La cartografía automática de coberturas terrestres en zonas urbanas europeas enfrenta dificultades de generalización entre arquitecturas CNN. Cecili et al. [21] compararon modelos VGG16, DenseNet121 y ResNet50 sobre imágenes multitemporales y monofecha Sentinel-2 para mapear coberturas de tierra en Roma, Italia. El aporte es la producción de un mapa de cobertura compatible con el estándar EAGLE usando VGG16 como mejor modelo, con metodología replicable para otras ciudades. La metodología evaluó los tres modelos CNN sobre imágenes de 2019 con bandas RGB de Sentinel-2, midiendo exactitud global y calidad del mapa generado. VGG16 alcanzó 71% de exactitud global tanto en imágenes monofecha como multitemporales. La limitación es su contexto urbano europeo, muy distante del entorno de selva tropical amazónica.

La fusión de múltiples fuentes de datos satelitales mediante CNN mejora la exactitud de clasificación en coberturas complejas. Ye et al. [22] propusieron el algoritmo DB-CNN para la fusión y clasificación de datos de teledetección multi-fuente, alcanzando 98.46% de exactitud global y un AUC de 0.922 en la curva ROC. La recuperación de parámetros ambientales mediante Sentinel-2 y algoritmos de Machine Learning demuestra la versatilidad de las imágenes satelitales para el monitoreo ecológico a escala regional [23]. Estos trabajos amplían el espectro de aplicaciones de la Visión Computacional en teledetección y refuerzan la pertinencia del enfoque propuesto en el presente trabajo.

Los trabajos revisados demuestran que el Deep Learning supera sistemáticamente a los métodos estadísticos en la detección de minería ilegal y deforestación mediante imágenes satelitales. Sin embargo, ninguno de los trabajos analizados aplica Transfer Learning con ResNet50 preentrenada en ImageNet sobre el dataset específico de la Amazonía peruana (Amazonia Garimpo Binario, 111,584 imágenes) con recortes de 128×128 píxeles etiquetados directamente como garimpo o no garimpo. Los enfoques revisados utilizan imágenes de otras regiones geográficas, arquitecturas distintas o targets de clasificación multiclase. El presente trabajo llena esta brecha mediante un clasificador binario ResNet50 fine-tuned sobre datos nativos de la región de interés.

TABLE I
COMPARATIVA DE TRABAJOS RELACIONADOS SOBRE DETECCIÓN DE MINERÍA
ILEGAL Y DEFORESTACIÓN MEDIANTE DEEP LEARNING.

Autores	Problema	Aporte	Metodología	Deficiencia
Adegun (2023)	Clasificación satelital limitada	Revisión CNN+ViT en 3 datasets	ResNet, DenseNet, VGG, EfficientNet	No representa ecosistemas tropicales
Balaniuk (2020)	Minas ilegales no registradas BR	263 minas ilegales descubiertas	FCN + Sentinel-2 + GEE	No clasifica legalidad
Camalan (2022)	Cambios en lagunas auríferas MDD	E-ReCNN + histograma matching	Sentinel-2 6ch + expertos dominio	Depende condiciones atmosféricas
Couttenier (2022)	Minería artesanal sin monitoreo	1er mapa masivo 13 países África	CNN segmentación + 1.75M km²	Recall bajo (42%)
De Bem (2020)	Deforestación amazónica anual	ResUnet > RF/MLP sin postproceso	SharpMask/U-Net/ResUnet vs RF/MLP	Solo detección anual
Gallwey (2020)	Minería artesanal Ghana	CNN multi-banda Sentinel-2 Ghana	Deep-to-Shallow CNN Sentinel-2	No generaliza a trópico
Lemes Neto (2026)	Nubes bloquean monitoreo óptico	CNN SAR viable bajo nubes	CNN + Sentinel-1 SAR	Baja densidad difícil de capturar
Pasanisi (2025)	Sin datos etiquetados Congo	Late Fusion óptico+SAR	Planet-NICFI + Sentinel-1 fusion	Confusión minería vs ciudad
Saire Rimachi (2024)	Sin CNN en español para Perú	Precedente latinoamericano	CNN + imágenes satelitales Perú	Dataset pequeño
Shashidhara (2025)	Sin localización en tiempo real	CNN+YOLO+Flask plataforma web	Flask+ResNet121 + YOLO + Flask	Cobertura geográfica reducida
Cecili (2023)	Mapeo coberturas urbanas Europa	Mapa EA-GLE Roma con VGG16	VGG16/DenseNet121/ResNet50 Sentinel-2	No transfiere a selva tropical

III. FUNDAMENTOS TEÓRICOS

A. Inteligencia Artificial y Aprendizaje Supervisado

La Inteligencia Artificial (IA) es la disciplina que estudia el diseño de sistemas capaces de percibir su entorno y tomar decisiones autónomas para alcanzar objetivos predefinidos. La IA abarca desde sistemas basados en reglas explícitas

hasta modelos que aprenden patrones directamente de los datos. El Aprendizaje Automático (Machine Learning, ML) es la rama de la IA que permite a un sistema mejorar su desempeño en una tarea a partir de la experiencia, sin ser programado explícitamente para cada caso. El ML se clasifica en tres paradigmas: aprendizaje supervisado, no supervisado y por refuerzo.

El aprendizaje supervisado entrena un modelo con pares de datos etiquetados (entrada X , salida Y) para que aprenda una función de mapeo $f : X \rightarrow Y$. En la clasificación binaria, el modelo predice una de dos clases posibles: en este trabajo, presencia (1) o ausencia (0) de garimpo. La función de pérdida binaria cross-entropy cuantifica el error entre la predicción del modelo y la etiqueta real. El modelo minimiza esta función mediante el algoritmo de descenso de gradiente estocástico a lo largo de múltiples épocas de entrenamiento.

B. Visión Computacional

La Visión Computacional es la rama de la IA que permite a los sistemas interpretar y comprender información visual proveniente del mundo real. Sus aplicaciones incluyen clasificación de imágenes, detección de objetos, segmentación semántica y reconocimiento de patrones en imágenes satelitales. El procesamiento de imágenes satelitales multi-espectrales requiere técnicas capaces de manejar múltiples canales de información simultáneamente. La combinación de Visión Computacional con el Deep Learning ha revolucionado la capacidad de los sistemas automáticos para analizar imágenes complejas a escala.

C. Redes Neuronales Convolucionales

Las Redes Neuronales Convolucionales (CNN) son arquitecturas de aprendizaje profundo diseñadas para procesar datos con estructura de cuadrícula, como imágenes. Una CNN aplica filtros convolucionales aprendibles que extraen jerarquías de características visuales: bordes y texturas en capas superficiales, y patrones semánticos complejos en capas profundas. El proceso de convolución preserva las relaciones espaciales locales de la imagen, lo que lo hace ideal para imágenes satelitales donde la posición relativa de los píxeles importa. La operación de pooling reduce la dimensionalidad espacial, controlando el sobreajuste y haciendo al modelo invariante a pequeñas traslaciones.

D. ResNet y Conexiones Residuales

El problema del desvanecimiento del gradiente limita el entrenamiento de redes neuronales profundas con decenas de capas [24]. ResNet (Residual Network) resolvió este problema mediante conexiones de salto (skip connections) que permiten que el gradiente fluya directamente desde capas de salida hasta capas de entrada sin degradarse [25]. Formalmente, si $H(x)$ es la función objetivo, la red aprende el residuo $F(x) = H(x) - x$, simplificando el proceso de optimización. ResNet50, la variante de 50 capas utilizada en este trabajo, alcanza alta exactitud en tareas de clasificación de imágenes con menor costo computacional que arquitecturas anteriores más profundas.

E. VGG16 como Línea Base Comparativa

VGG16 es una arquitectura CNN compuesta por 16 capas con pesos aprendibles, caracterizada por su diseño uniforme de bloques de convolución con filtros 3×3. Su arquitectura simple y regular la convierte en el punto de referencia estándar para comparar el rendimiento de redes más modernas. En la comparación empírica de Inception V3, VGG16, VGG19, CNN base y ResNet50, ResNet50 alcanzó 99.75% de exactitud y 99.50% de precisión, superando a VGG16 en todas las métricas [26]. En este trabajo, VGG16 se emplea como arquitectura de referencia para cuantificar la mejora que aporta ResNet50.

F. Transfer Learning

El Transfer Learning reutiliza pesos pre-entrenados en una tarea de origen (ImageNet, 1.2 millones de imágenes) y los transfiere a una tarea de destino distinta mediante fine-tuning [27]. Esta estrategia reduce el tiempo de entrenamiento, el requerimiento de datos etiquetados y el costo computacional. Naushad et al. aplicaron Transfer Learning con VGG16 y Wide Residual Networks sobre EuroSAT, alcanzando 99.17% de exactitud en clasificación de uso y cobertura del suelo [27]. En contextos de datos escasos en teledetección, técnicas como el aumento de datos y el aprendizaje por transferencia son especialmente eficaces para superar las limitaciones del tamaño del dataset [28]. En este trabajo, ResNet50 pre-entrenada en ImageNet es fine-tuned sobre las 111,584 imágenes del dataset Amazonia Garimpo Binario.

G. Métricas de Evaluación

La evaluación del desempeño de un clasificador binario requiere métricas complementarias derivadas de la matriz de confusión [29]. La matriz de confusión organiza los resultados en cuatro categorías: Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN). La Exactitud ($\text{Accuracy} = (\text{VP} + \text{VN}) / (\text{VP} + \text{VN} + \text{FP} + \text{FN})$) mide la proporción global de predicciones correctas. La Precisión ($\text{Precision} = \text{VP} / (\text{VP} + \text{FP})$) cuantifica las alertas de garimpo correctas, mientras que el Recall ($\text{Recall} = \text{VP} / (\text{VP} + \text{FN})$) mide el garimpo real detectado. El F1-score, media armónica de precisión y recall, balancea ambas métricas en un único indicador. Aunque el dataset presenta un balance perfecto de 50/50 en su distribución de clases, se empleará el AUC-ROC para evaluar la capacidad del modelo en distintos umbrales de decisión y priorizar el Recall [30].

H. Herramientas y Tecnologías

Python 3.14 es el lenguaje de programación estándar para el análisis de datos científicos y el desarrollo de modelos de aprendizaje automático. Jupyter Notebook proporciona un entorno interactivo que facilita la exploración iterativa de datos y la documentación integrada del análisis. NumPy y Pandas se utilizan para la carga, inspección y preprocesamiento del archivo manifesto_chips.csv con las 111,584 rutas de imágenes y sus etiquetas binarias. La combinación de estas herramientas conforma el ecosistema estándar para la estructuración de matrices de datos en proyectos de ciencia de datos aplicada.

El preprocesamiento de imágenes, que incluye normalización al rango [0,1], aumento de datos (rotaciones, flips, zoom) y partición estratificada, se implementa con Keras y Scikit-learn. TensorFlow/Keras provee las API de alto nivel para la construcción, compilación y entrenamiento del modelo ResNet50. Scikit-learn complementa el pipeline con herramientas para partición estratificada, matriz de confusión y curva ROC. La portabilidad del entorno sobre Google Colab permite reproducir todos los experimentos sin hardware local especializado.

I. Dataset: Amazonia Garimpo Binario

El conjunto de datos utilizado es el “Dataset Amazonia Garimpo Binario”, elaborado por Grupioni (2024) y disponible públicamente en Kaggle. El dataset contiene 111,584 recortes satelitales de 128×128 píxeles en formato PNG, organizados en el archivo manifesto_chips.csv. La variable de entrada X corresponde a la columna png_path, que almacena la ruta relativa a cada imagen. La variable objetivo Y es label_int, donde el valor 1 indica presencia de garimpo y el valor 0 indica ausencia.

TABLE II
DESCRIPCIÓN DE LAS COLUMNAS DEL ARCHIVO MANIFESTO_CHIPS.CSV.

Columna	Tipo	Rol	Descripción
png_path	string	Variable X	Ruta relativa al archivo PNG de la imagen satelital
label_int	entero (0/1)	Variable Y	0 = sin garimpo, 1 = con garimpo
label_str	string	Referencia	sem_garimpo o com_garimpo

TABLE III
AUNQUE EL DATASET PRESENTA UN BALANCE PERFECTO DE 50/50 EN SU DISTRIBUCIÓN DE CLASES, SE EMPLEARÁ EL AUC-ROC PARA EVALUAR LA CAPACIDAD DEL MODELO EN DISTINTOS UMBRALES DE DECISIÓN Y PRIORIZAR EL RECALL.

Clase	Cantidad	Proporción
Sin garimpo (0)	55,792	50.0%
Con garimpo (1)	55,792	50.0%
Total	111,584	100%

REFERENCES

- [1] “Illegal Mining in the Amazon Hits Record High amid Indigenous Protests.” 2021.
- [2] L. C. Ferreira Neto *et al.*, “Uncontrolled Illegal Mining and Garimpo in the Brazilian Amazon,” *Nature Communications*, vol. 15, 2024, doi: 10.1038/s41467-024-54220-2.
- [3] “Peru’s Gold Rush Prompts Public-Health Emergency.” 2016.
- [4] “The Case of the Floating Gold Miners’ Village on the Madeira River,” *The Extractive Industries and Society*, 2022.
- [5] J. R. Gerson *et al.*, “Amazon Forests Capture High Levels of Atmospheric Mercury Pollution from Artisanal Gold Mining,” *Nature Communications*, vol. 13, 2022, doi: 10.1038/s41467-022-27997-3.
- [6] “Mercury in the Amazon: The Danger of a Single Story,” *Environmental Toxicology and Pharmacology*, 2023.
- [7] MAAP, “Evaluación de Deforestación Por Minería Aurífera En Madre de Dios, Perú.” 2023.

- [8] "Twenty Years of Land Cover Change in the Southeastern Peruvian Amazon: Implications for Biodiversity Conservation," *Regional Environmental Change*, 2020, doi: 10.1007/s10113-020-01603-y.
- [9] F. D. L. Lobo, P. W. M. Souza-Filho, E. M. L. D. M. Novo, F. M. Carlos, and C. C. F. Barbosa, "Mapping Mining Areas in the Brazilian Amazon Using MSI/Sentinel-2 Imagery (2017)," *Remote Sensing*, vol. 10, no. 8, p. 1178, Jul. 2018, doi: 10.3390/rs10081178.
- [10] "Land Use/Land Cover Change Classification and Prediction Using Deep Learning Approaches," *Signal, Image and Video Processing*, 2023, doi: 10.1007/s11760-023-02701-0.
- [11] A. A. Adegun, S. Viriri, and J.-R. Tapamo, "Review of Deep Learning Methods for Remote Sensing Satellite Images Classification: Experimental Survey and Comparative Analysis," *Journal of Big Data*, vol. 10, no. 1, p. 93, Jun. 2023, doi: 10.1186/s40537-023-00772-x.
- [12] R. Balaniuk, O. Isupova, and S. Reece, "Mining and Tailings Dam Detection in Satellite Imagery Using Deep Learning," *Sensors*, vol. 20, no. 23, p. 6936, Dec. 2020, doi: 10.3390/s20236936.
- [13] S. Camalan *et al.*, "Change Detection of Amazonian Alluvial Gold Mining Using Deep Learning and Sentinel-2 Imagery," *Remote Sensing*, vol. 14, no. 7, p. 1746, Apr. 2022, doi: 10.3390/rs14071746.
- [14] M. Couttenier, S. Di Rollo, L. Inguere, M. Mohand, and L. Schmidt, "Mapping Artisanal and Small-Scale Mines at Large Scale from Space with Deep Learning," *PLOS ONE*, vol. 17, no. 9, p. e0267963, Sep. 2022, doi: 10.1371/journal.pone.0267963.
- [15] P. De Bem, O. De Carvalho Junior, R. Fontes Guimarães, and R. Trancoso Gomes, "Change Detection of Deforestation in the Brazilian Amazon Using Landsat Data and Convolutional Neural Networks," *Remote Sensing*, vol. 12, no. 6, p. 901, Mar. 2020, doi: 10.3390/rs12060901.
- [16] J. Gallwey, C. Robiati, J. Coggan, D. Vogt, and M. Eyre, "A Sentinel-2 Based Multispectral Convolutional Neural Network for Detecting Artisanal Small-Scale Mining in Ghana: Applying Deep Learning to Shallow Mining," *Remote Sensing of Environment*, vol. 248, p. 111970, Oct. 2020, doi: 10.1016/j.rse.2020.111970.
- [17] N. Lemes Neto, M. D. L. B. T. Galo, R. A. De Oliveira, F. S. Y. Watanabe, and M. Galo, "Towards SAR-Based Monitoring of Illegal Mining in the Brazilian Amazon Using Convolutional Neural Networks," *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. X-3/W4-2025, pp. 205–212, Mar. 2026, doi: 10.5194/isprs-annals-X-3-W4-2025-205-2026.
- [18] F. Pasanisi, R. N. Masolele, and J. Reiche, "Using High-Resolution Satellite Imagery and Deep Learning to Map Artisanal Mining Spatial Extent in the Democratic Republic of the Congo," *Remote Sensing*, vol. 17, no. 24, p. 4057, Dec. 2025, doi: 10.3390/rs17244057.
- [19] V. W. Saire Rimachi, M. Vela Quispe, R.-N. Aragón Navarrete, N. J. Ulloa Gallardo, and L. Holgado Apaza, "Detección de Deforestación Por Actividades Mineras y Agrícolas Mediante Redes Neuronales Convolucionales," *RISTI*, 2024.
- [20] Shashidhara S and Thouseef Ulla Khan, "Illegal Mining Activity Detection Using Satellite Images," *International Journal of Advanced Research in Science, Communication and Technology*, pp. 383–391, Nov. 2025, doi: 10.48175/IJARSCT-29949.
- [21] G. Cecili, P. De Fioravante, P. Dichicco, L. Congedo, M. Marchetti, and M. Munafò, "Land Cover Mapping with Convolutional Neural Networks Using Sentinel-2 Images: Case Study of Rome," *Land*, vol. 12, no. 4, p. 879, Apr. 2023, doi: 10.3390/land12040879.
- [22] F. Ye, Z. Zhou, Y. Wu, and B. Enkhtur, "Application of Convolutional Neural Network in Fusion and Classification of Multi-Source Remote Sensing Data," *Frontiers in Neurorobotics*, vol. 16, p. 1095717, Dec. 2022, doi: 10.3389/fnbot.2022.1095717.
- [23] Y. Tian and others, "Remote Sensing Retrieval of Inland Water Quality Parameters Using Sentinel-2 and Multiple Machine Learning Algorithms," *Environmental Science and Pollution Research*, 2023, doi: 10.1007/s11356-022-23431-9.
- [24] "Deep Residual Learning for Image Recognition: A Survey."
- [25] O. K. Oyedotun, K. A. Ismaeil, and D. Aouada, "Why Is Everyone Training Very Deep Neural Network With Skip Connections?," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 9, pp. 5961–5975, Sep. 2023, doi: 10.1109/TNNLS.2021.3131813.
- [26] S. R. Shah, S. Qadri, H. Bibi, S. M. W. Shah, M. I. Sharif, and F. Marinello, "Comparing Inception V3, VGG 16, VGG 19, CNN, and ResNet 50: A Case Study on Early Detection of a Rice Disease," *Agronomy*, vol. 13, no. 6, p. 1633, Jun. 2023, doi: 10.3390/agronomy13061633.
- [27] R. Naushad, T. Kaur, and E. Ghaderpour, "Deep Transfer Learning for Land Use and Land Cover Classification: A Comparative Study," *Sensors*, vol. 21, no. 23, p. 8083, Jan. 2021, doi: 10.3390/s21238083.
- [28] A. Safonova, G. Ghazaryan, S. Stiller, M. Main-Knorn, C. Nendel, and M. Ryo, "Ten Deep Learning Techniques to Address Small Data Problems with Remote Sensing," *International Journal of Applied Earth Observation and Geoinformation*, vol. 125, p. 103569, Dec. 2023, doi: 10.1016/j.jag.2023.103569.
- [29] O. Rainio, J. Teuho, and R. Klén, "Evaluation Metrics and Statistical Tests for Machine Learning," *Scientific Reports*, vol. 14, no. 1, p. 6086, Mar. 2024, doi: 10.1038/s41598-024-56706-x.
- [30] E. Richardson, R. Trevizani, J. A. Greenbaum, H. Carter, M. Nielsen, and B. Peters, "The Receiver Operating Characteristic Curve Accurately Assesses Imbalanced Datasets," *Patterns*, vol. 5, no. 6, p. 100994, Jun. 2024, doi: 10.1016/j.patter.2024.100994.